

Algebra Recap

1) Calculate the projection of $v = (1, 2, 3, 4)$ on $w = (0, -1, 1, 2)$

$$\|v\| \cos \theta \text{proj}_w v = \frac{\langle v, w \rangle}{\|w\|^2} w$$

$$p = \|v\| \cos \theta \frac{\langle v, w \rangle}{\|w\|^2} w = \frac{\langle v, w \rangle}{\|w\|^2} w$$

$$= \frac{-2 + 3 + 8}{1+1+4} (0, -1, 1, 2) = \frac{9}{2} (0, -1, 1, 2)$$

$$= (0, -\frac{9}{2}, \frac{9}{2}, 9)$$

2) Calculate the projection of $v = (1, 2, 3, 4)$ on $w = (1, 0, 1, -1)$

$$p = \frac{\langle v, w \rangle}{\|w\|^2} w = \frac{1+3-4}{1+1+1} (1, 0, 1, -1) = (0, 0, 0, 0)$$

$$= \vec{0} \quad (\text{Orthogonal})$$

3) Prove the angle between two non-zero vectors $v, w \in \mathbb{R}^m$ is $\pm 90^\circ$ iff $\langle v, w \rangle = 0$

$$\theta = \pm 90^\circ \text{ iff } \langle v, w \rangle = 0 \quad \text{if } v, w \in \mathbb{R}^m$$

$$V = (v_1, \dots, v_m) \quad W = (w_1, \dots, w_m)$$

$$\langle v, w \rangle = \sum_{i=1}^m v_i w_i$$

$$\|v\| \|w\| \cos \theta = \langle v, w \rangle$$

$$\langle v, w \rangle = 0 \quad \text{iff} \quad \cos \theta = \cos(90^\circ) = 0$$

$$\theta = \pm 90^\circ \text{ iff } \langle v, w \rangle = 0 \quad \text{if } v, w \in \mathbb{R}^m$$

$$\|v\| \|w\| \cos \theta = 0 \quad \text{iff} \quad \langle v, w \rangle = 0$$

$$\cos \theta = 0 \quad \text{iff} \quad v \perp w \quad \text{iff} \quad \theta = \pm 90^\circ$$

$$\|v - w\|^2 = \langle v - w, v - w \rangle = \|v\|^2 + \|w\|^2 - 2 \langle v, w \rangle *$$

$$\|v - w\|^2 = \|v\|^2 + \|w\|^2 - 2 \|v\| \|w\| \cos \theta$$

$$-\cancel{2} \|v\| \|w\| \cos \theta = -2 \langle v, w \rangle$$

4) Prove that Orthonormal matrices are isometric transformations. That is. Let $T: V \rightarrow W$ be some linear transformation and A the corresponding matrix. Then if A is orthonormal then $\forall x \in V$. $\|Ax\|_2 = \|x\|_2$

הנ' $T: V \rightarrow W$ הומומורפיזם א-הומולוגי של מרחב וקטורי

$T(u+v) = T(u) + T(v)$ ו, $T(cu) = cT(u)$ $u, v \in V, c \in \mathbb{R}$ גורן

$$\|x\|_2 = \left(\sum_{i=1}^m |x_i|^2 \right)^{\frac{1}{2}}$$

'ג. וקטור היקף

$AA^T = A^TA = I \iff$ תבניות הנערכות A

$$\begin{aligned}\|Ax\|_2^2 &= \langle Ax, Ax \rangle - \left\langle \sum_i a_{ij}x_j, \sum_j a_{ij}x_j \right\rangle \\ &= \langle A^T Ax, x \rangle \quad A^T A = I \text{ if } h \in \text{range } A \\ &= \langle x, x \rangle = \|x\|^2\end{aligned}$$

$$\|Ax\|_2^2 = \langle Ax, Ax \rangle = (Ax)^T Ax = x^T A^T Ax$$

$$A^T A = X^T I X = X^T X = \langle X, X \rangle = \|X\|_2^2$$

SVD

5) Assume A is invertible. Write a formula for the inverse of A using only the matrices U, D, V where UDV^T is an SVD decomposition of A . Explain why knowing the SVD decomposition of matrix is useful.

$$\begin{aligned} & \text{Given } \text{cond. } \sigma' \\ & \Rightarrow U^T U = U U^T = I \\ & \Rightarrow V^T V = V V^T = I \\ & \text{From } U = V D V^{-1} \\ & \Rightarrow U^T = V^{-1} D V^T \\ & \Rightarrow U^T U = V^{-1} D V^T U = V^{-1} D V = I \\ & \Rightarrow D = V^{-1} U^T V \end{aligned}$$

$$\boldsymbol{\theta} = \boldsymbol{U} \boldsymbol{D} \boldsymbol{V}^T$$

$$A^{-1} = V D^{-1} U^T$$

$$D^{-1} = \begin{pmatrix} 1 & & & \\ s_1 & \ddots & & \\ & \ddots & \ddots & \\ & 0 & & s_1 \end{pmatrix}$$

D סדרה היבשתית
D פלטפורמה
ו-ארכיטקטורה
ב-סינטזה

$$A^{-1}A = (V D^{-1} U^T)(U D V^T) \quad \text{הנימוק השני}$$

הנימוק הראשון

$$= V D^{-1} (U^T U) D V^T$$

$$= V D^{-1} I D V^T$$

$$\xrightarrow{\text{הנימוק השני}} = V D^{-1} D V^T$$

$$= V I V^T$$

$$= V V^T = I \quad \Rightarrow \text{הנימוק השלישי } A^{-1} = V D^{-1} U^T$$

הנימוק השלישי

סימנה - הכוון ב-V-7 או אף סורה אחרת (הרוכאה-ז) בסתת עלייה (האינטראקציית P, המצא צפוי).

$$\tilde{x} \xrightarrow[\text{rotation}]{V^T} V^T \tilde{x} \xrightarrow[\text{Streching}]{D} DV^T \tilde{x} \xrightarrow[\text{rotation}]{U} UDV^T \tilde{x}$$

$$\tilde{x} \leftarrow V^T x \leftarrow D^{-1} DV^T \tilde{x} \leftarrow UDV^T \tilde{x}$$

$$\widehat{x} = A^{-1}A\widehat{x} = (VD^{-1}U^T)(UDV^T)\widehat{x}$$

כטביה נהורטה נ-א כטביה נהורטה נ-א כטביה נהורטה נ-א כטביה נהורטה נ-א כטביה נהורטה נ-א

• ewe SVD x3u wo? ↑

6) Find an SVD of $C = \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix}$

• calculate $C^T C$

$$\begin{pmatrix} 5 & -1 \\ 5 & 7 \end{pmatrix} \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix} = \begin{pmatrix} 26 & 18 \\ 18 & 74 \end{pmatrix}$$

• Deduce V and D

$$\begin{aligned} \det(C^T C - \lambda I) &= \begin{vmatrix} 26-\lambda & 18 \\ 18 & 74-\lambda \end{vmatrix} = (26-\lambda)(74-\lambda) - 324 \\ &= 1924 - 100\lambda + \lambda^2 - 324 \\ &= \lambda^2 - 100\lambda + 1600 \\ &= (\lambda - 20)(\lambda - 80) \end{aligned}$$

$$\lambda_1 = \underline{\underline{20}}, \lambda_2 = \underline{\underline{80}} \text{ so } \leftarrow$$

$$\begin{aligned} C^T C + 20I &= \begin{pmatrix} 6 & 18 \\ 18 & 54 \end{pmatrix} - 6 \begin{pmatrix} 1 & 3 \\ 3 & 9 \end{pmatrix} \\ \Rightarrow 6 \begin{pmatrix} 1 & 3 \\ 3 & 9 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} &= \begin{pmatrix} 0 \\ 0 \end{pmatrix} \end{aligned}$$

$$\begin{aligned} V_1 + 3V_2 &= 0 \\ 3V_1 + 9V_2 &= 0 \end{aligned} \Rightarrow V_1 = -3V_2 \Rightarrow V_{\lambda_1} = \begin{pmatrix} -3 \\ 1 \end{pmatrix} \frac{1}{\sqrt{10}}$$

$$C^T C - 80I = \begin{pmatrix} -54 & 18 \\ 18 & -60 \end{pmatrix} = 6 \begin{pmatrix} -9 & 3 \\ 3 & -1 \end{pmatrix}$$

$$\Rightarrow 6 \begin{pmatrix} -9 & 3 \\ 3 & -1 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\begin{aligned} -9V_1 + 3V_2 &= 0 \\ 3V_1 + V_2 &= 0 \end{aligned} \Rightarrow V_2 = 3V_1 \Rightarrow V_{\lambda_2} = \begin{pmatrix} 1 \\ 3 \end{pmatrix} \frac{1}{\sqrt{10}}$$

$$V = \begin{pmatrix} v_1 & v_2 \\ V_{\lambda_1} & V_{\lambda_2} \end{pmatrix} = \begin{pmatrix} -\frac{3}{\sqrt{10}} & \frac{1}{\sqrt{10}} \\ \frac{1}{\sqrt{10}} & \frac{3}{\sqrt{10}} \end{pmatrix}$$

$$D = \begin{pmatrix} \sqrt{\lambda_1} & 0 \\ 0 & \sqrt{\lambda_2} \end{pmatrix} = \begin{pmatrix} 2\sqrt{5} & 0 \\ 0 & 4\sqrt{5} \end{pmatrix}$$

ולכן D סימetricOrthogonal $\Rightarrow D = U D$
ולכן $C = U D V^T$

• Find U using $CV = UD$

$$CV = \begin{pmatrix} 5 & 5 \\ -1 & 7 \end{pmatrix} \frac{1}{\sqrt{10}} \begin{pmatrix} -3 & 1 \\ 1 & 3 \end{pmatrix} = \frac{1}{\sqrt{10}} \begin{pmatrix} -10 & 20 \\ 10 & 20 \end{pmatrix}$$

$$= \sqrt{10} \begin{pmatrix} -1 & 2 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} 2\sqrt{5} & 0 \\ 0 & 4\sqrt{5} \end{pmatrix}$$

ולכן U סימetricOrthogonal $\Rightarrow U = D^{-1} V$

ולכן U

$$\#) C_0 = A^T A \quad , \quad A \in M_{n \times m} (\mathbb{R})$$

$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ וענ' דע' כהה שי (v_1, \dots, v_n)

$$b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|}, \quad b_0 = \sum_{i=1}^n a_i v_i$$

$$\lim_{k \rightarrow \infty} b_k = \pm v_i \quad B$$

$$C_0 = A^T A = \left(U \sum V^T \right)^T \left(U \sum V^T \right). \quad (1)$$

$$= U \sum V^T U^T U \sum V^T = V \sum U^T V^T = V \sum V^T$$

היכיינע עז זיהויים

0-N פס' EVD מיל' $\Sigma' = \sum V^T$ גודל גורם σ_i \leftarrow
 P-FP א. A ב. SVD נפלטן ס. Σ' ג. v_i ה. a_i ג. σ_i ד. V^T ה. V

$$b_k = \frac{C_0^k b_0}{\|C_0^k b_0\|} \quad \text{ר'ב' } k \in N \text{ ג' } \in \mathbb{R}$$

$$b_1 = \frac{C_0 b_0}{\|C_0 b_0\|} = \frac{C_0 b_0}{\|C_0 b_0\|} \quad \text{עפ' כ' ש' } k=1 \text{ ג' } \in N$$

ה' b_1 יתג'ר v_1 וענ' $k=1$ ג' $\in N$

$$b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|} = \frac{C_0 \cdot C_0^k b_0}{\|C_0 C_0^k b_0\|} = \frac{C_0^{k+1} b_0}{\|C_0^{k+1} b_0\|} \quad (2)$$

$$C_0^k b_0 = \left(V \sum V^T \right)^k b_0 \quad (3)$$

$$\sum^{2k} = \begin{pmatrix} \lambda_1^{2k} & & 0 \\ & \ddots & \\ 0 & & \lambda_n^{2k} \end{pmatrix} = \lambda_1^{2k} \begin{pmatrix} 1 & & \\ & \frac{\lambda_2^{2k}}{\lambda_1^{2k}} & \\ & & \ddots & \frac{\lambda_n^{2k}}{\lambda_1^{2k}} \end{pmatrix}$$

ה' λ_1 ה' λ_2 ה' λ_n

$$2k=m \quad (4) = \lambda_1^m \begin{pmatrix} 1 & & & \\ & \left(\frac{\lambda_2}{\lambda_1}\right)^m & & \\ & & \ddots & \\ & & & \left(\frac{\lambda_n}{\lambda_1}\right)^m \end{pmatrix} =$$

$\downarrow \quad \left\{ \begin{array}{l} j \leq n \text{ ג' } \\ \text{ר'ב' } \end{array} \right.$

$$\xrightarrow{k \rightarrow \infty} \begin{pmatrix} 1 & 0 & 0 & \dots \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & \ddots & 0 \end{pmatrix} = (1)^{-m} \quad \begin{array}{l} \text{ר'ב' } \\ \frac{\lambda_j}{\lambda_1} < 1 \\ \left(\frac{\lambda_j}{\lambda_1}\right)^m \xrightarrow{m \rightarrow \infty} 0 \end{array}$$

$$\Rightarrow b_{k+1} = \frac{C_0^k b_0}{\|C_0^k b_0\|} = \frac{\sqrt{\sum V^T b_0}}{\|V \sum V^T b_0\|} \xrightarrow{k \rightarrow \infty} \frac{\sqrt{Q V^T b_0}}{\|V Q V^T b_0\|}$$

$$a_1 \neq 0 \quad = \frac{V_1 V_1^T b_0}{\|V_1 V_1^T b_0\|} = \frac{V_1 V_1^T \sum a_i v_i}{\|V_1 V_1^T \sum a_i v_i\|} = \frac{a_1 v_1}{\|a_1 v_1\|} = \frac{a_1}{\|a_1\|} v_1$$

Multivariate Calculus

8) Let $x \in \mathbb{R}^n$ be a fixed vector and $U \in \mathbb{R}^{n \times n}$ a fixed orthogonal matrix. Calculate the Jacobian of $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$:

$$f(\tilde{\sigma}) = U \operatorname{diag}(\tilde{\sigma}) U^T x$$

$$\operatorname{diag}(\tilde{\sigma})_{ij} = \begin{cases} \tilde{\sigma}_i & i=j \\ 0 & i \neq j \end{cases}$$

$$\begin{pmatrix} U_{11} & U_{12} & \dots & U_{1n} \\ U_{21} & U_{22} & \dots & U_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ U_{n1} & U_{n2} & \dots & U_{nn} \end{pmatrix} \begin{pmatrix} \tilde{\sigma}_1 & & 0 \\ & \tilde{\sigma}_2 & \\ 0 & & \ddots & \tilde{\sigma}_n \end{pmatrix} \begin{pmatrix} U_{11} & & U_{1n} \\ U_{21} & & U_{2n} \\ \vdots & & \vdots \\ U_{n1} & & U_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

$$= \begin{pmatrix} U_{11} & \dots & U_{1n} \\ \vdots & \ddots & \vdots \\ U_{n1} & \dots & U_{nn} \end{pmatrix} \begin{pmatrix} U_{11} \tilde{\sigma}_1 & & U_{1n} x_n \tilde{\sigma}_n \\ U_{21} \tilde{\sigma}_1 & \ddots & \vdots \\ \vdots & \vdots & \vdots \\ U_{n1} \tilde{\sigma}_1 & \dots & U_{nn} x_n \tilde{\sigma}_n \end{pmatrix}$$

$$= \begin{pmatrix} U_{11} & \dots & U_{1n} \\ \vdots & \ddots & \vdots \\ U_{n1} & \dots & U_{nn} \end{pmatrix} \begin{pmatrix} U_{11} x_1 \tilde{\sigma}_1 & \dots & U_{1n} x_n \tilde{\sigma}_n \\ U_{21} x_1 \tilde{\sigma}_1 & \ddots & \vdots \\ \vdots & \vdots & \vdots \\ U_{n1} x_1 \tilde{\sigma}_1 & \dots & U_{nn} x_n \tilde{\sigma}_n \end{pmatrix}$$

$$= \begin{pmatrix} U_{11}^2 x_1 \tilde{\sigma}_1 + \dots + U_{1n}^2 x_n \tilde{\sigma}_n & & U_{11} U_{12} x_1 \tilde{\sigma}_2 + \dots + U_{1n} U_{2n} x_n \tilde{\sigma}_n \\ & \ddots & \\ & & U_{11} U_{nn} x_1 \tilde{\sigma}_n + \dots + U_{nn}^2 x_n \tilde{\sigma}_n \end{pmatrix}$$

$$f(\tilde{\sigma}) = \sum_{i=1}^n \tilde{\sigma}_i U_i U_i^T x \quad \leftarrow$$

$$\Rightarrow \frac{\partial f_i(\tilde{\sigma})}{\partial \tilde{\sigma}_j} = [U_i U_i^T x]_j$$

$$\Rightarrow U_i \cdot \langle U_i, x \rangle \quad (\text{why}) \quad \text{if } i=j \text{ then } \text{else}$$

$$\Rightarrow J f = U \operatorname{diag}(U^T x) = \sum_{i=1}^n U_i U_i^T x$$

$$\operatorname{diag}(U^T x)_{ij} = \begin{cases} U_i^T x & i=j \\ 0 & \text{else} \end{cases}$$

9) Calculate the gradient of

$$h(\tilde{\sigma}) = \frac{1}{2} \| f(\tilde{\sigma}) - y \|^2$$

$$= \frac{1}{2} \sum_{i=1}^d (f_i(\tilde{\sigma}) - y_i)^2$$

$$\frac{\partial h(\tilde{\sigma})}{\partial \tilde{\sigma}_i} = \frac{1}{2} \cdot 2(f_i(\tilde{\sigma}) - y_i) \cdot \frac{\partial f_i(\tilde{\sigma})}{\partial \tilde{\sigma}_i}$$

$$\nabla h(\tilde{\sigma}) = (f(\tilde{\sigma}) - y)^\top \nabla f(\tilde{\sigma})$$

$$\left\{ \begin{array}{l} h(\tilde{\sigma}) = \frac{1}{2} \sum_{i=1}^d f_i^2(\tilde{\sigma}) - 2 f_i(\tilde{\sigma}) y_i + y_i^2 \\ \frac{\partial h(\tilde{\sigma})}{\partial \tilde{\sigma}_i} = \frac{1}{2} ((2 f_i(\tilde{\sigma}) - 2 y_i) \frac{\partial f_i(\tilde{\sigma})}{\partial \tilde{\sigma}_i}) \\ = (f_i(\tilde{\sigma}) - y_i) \frac{\partial f_i(\tilde{\sigma})}{\partial \tilde{\sigma}_i} \end{array} \right.$$

$$\nabla h(\tilde{\sigma}) = (f(\tilde{\sigma}) - y)^\top \nabla f(\tilde{\sigma}) \quad \text{however}$$

10) Calculate the Jacobian of the softmax function:

$$g(z)_i = \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}} \quad g(z): \mathbb{R}^K \rightarrow \mathbb{R}^K$$

$\forall i \in \{1, \dots, K\}$

בכדי למצוא ג'קוביאןsoftmax כפונקציה מ- \mathbb{R}^K ל- \mathbb{R}^K , נחקרו ורשים את ה- $\frac{\partial g_i}{\partial z_j}$ בדרכו.

$$= \frac{\partial}{\partial z_i} \left(\frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}} \right)$$

$$h_i = \sum_{k=1}^K e^{z_k}, \quad g_i = e^{z_i}$$

$$\frac{\partial}{\partial z_i} \left(\frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}} \right) = \frac{e^{z_i} \sum_{k=1}^K e^{z_k} - e^{z_i} \cdot e^{z_i}}{\left(\sum_{k=1}^K e^{z_k} \right)^2} \quad i=j \text{ מושג (I)}$$

$$= \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}} - \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}} \cdot \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}} = g_i \cdot (1 - g_i)$$

$$\frac{\partial}{\partial z_j} \left(\frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}} \right) = \frac{0 \cdot \sum_{k=1}^K e^{z_k} - e^{z_i} \cdot e^{z_j}}{\left(\sum_{k=1}^K e^{z_k} \right)^2} \quad i \neq j \text{ מושג (II)}$$

$$= - \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}} \cdot \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} = -g_i \cdot g_j$$

$$\frac{\partial g_i}{\partial z_j} = \begin{cases} g_i (1 - g_j) & \text{if } i=j \\ -g_i \cdot g_j & \text{else} \end{cases} \quad \leftarrow$$

$$= g_i (\delta_{ij} - g_j)$$

$$12) C = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \quad S = \begin{pmatrix} 0.1 & 0 & 0 \\ 0 & 0.5 & 0 \\ 0 & 0 & 2 \end{pmatrix} = S^T$$

$$\text{COV scale} = SCST = SI S^T = SS^T = S^2$$

$$= \begin{pmatrix} 0.1^2 & 0 & 0 \\ 0 & 0.5^2 & 0 \\ 0 & 0 & 2^2 \end{pmatrix} = \begin{pmatrix} 0.01 & \overset{\text{המוכן}}{0.05} & 0 \\ 0 & 0.25 & 0 \\ 0 & 0 & 4 \end{pmatrix}$$

$$\hat{C} = \frac{X_{\text{centered}} X^T_{\text{centered}}}{n-1} \begin{pmatrix} 0.995 & 0.005 & -0.008 \\ 0.005 & 0.998 & 0.002 \\ -0.008 & 0.002 & 1.001 \end{pmatrix} \sim \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\hat{C}_{\text{scale}} = \frac{SX \cdot (SX)^T}{n-1} = \frac{SX X^T S^T}{n-1} = S \hat{C} S^T$$

$$13) \hat{C}_{\text{orth+scale}} = H \frac{SX (HSX)^T}{n-1} = H S X X^T S^T H^T$$


$$= H \hat{C}_{\text{scale}} H^T$$

$$= H S^2 \hat{C} S^T H^T$$

מ"מorfic S-1 $C = I_{3 \times 3}$ מ"מ

ההסינוסים הדרושים ליצירת מטריצת \hat{C} מרכזים מ"מorfic מ"מ

ex1 IML




Q11:

Estimated covariance matrix of data

```
[[ 1.01499079e+00  7.00568292e-04 -1.50725425e-03]
 [ 7.00568292e-04  9.99304460e-01 -9.62534985e-03]
 [-1.50725425e-03 -9.62534985e-03  9.92500350e-01]]
```

כאשר מטריצת הקוריאנס היא מטריצת הזיהות כך שקיבלנו תוצאה שקרובה למציאות.

Q12:



ex1 IML


scaled covariance matrix

```
[[0.01 0. 0. ]
 [0. 0.25 0. ]
 [0. 0. 4. ]]
```

scaled estimated covariance matrix

```
[[ 1.01499079e-02 3.50284146e-05 -3.01450851e-04]
 [ 3.50284146e-05 2.49826115e-01 -9.62534985e-03]
 [-3.01450851e-04 -9.62534985e-03 3.97000140e+00]]
```

Q13:



Orthogonal Matrix

```
[[ -0.82500786 0.18560663 0.53377168]
 [-0.56104367 -0.38226727 -0.73423548]
 [ 0.06776447 -0.90521926 0.41950692]]
```

scaled orthogonal covariance matrix

```
[[ 1.15506765 -1.58076559 0.85312092]
 [-1.58076559 2.19608671 -1.14593873]
 [ 0.85312092 -1.14593873 0.90884564]]
```

scaled orthogonal estimated covariance matrix


```
[[ 1.1449643 -1.5657362 0.85044579]
 [-1.5657362 2.17429968 -1.14151557]]
```

ex1 IML

[0.85044579 -1.14151557 0.91071344]]


- 14.** Plot the projection of the data to the x, y axes. What does it look like?

האליפסה התקבלה כתוצאה בטרנספורמציה של מתייחה.
ניתן לראות שמדובר באלייפסה שהצירים שלה מיושרים עם הצירים u, x - קלומר הרכיבים בלתי מתואמים.



האליפסה התקבלה כתוצאה בטרנספורמציה של מתייחה וכפל במטריצה אורתוגונלית.
ניתן לראות שמדובר באלייפסה שהצירים שלה אינם מיושרים עם הצירים u, x - קלומר הרכיבים מתואמים.


ex1 IML



- 15.** Only for points where $0.1 > z > -0.4$: Plot the projection of the points to the x, y axes.
What does it look like?

אנחנו רואים מעגל שציריו מישרים לפ' הצללים z, x ומרכזו בראשית.

for $0.1 > z > -0.4$ - the projection of the points to the x, y axes





- 16.**

- a. Plot the estimate mean of all tosses up to m with 5 plots (each row in a different color).
כל שטיפות הדגימות גדול יותר כך המשערך יהיה יותר מדויק.

ex1 IML

עבור מ"מ שמתפלג בינומית התוחלת היא קח במקרה שלנו $\mu=0.25$ וולכן כמצופה כאשר מספר ההצלחות גבוהה נtractor לערך של התוחלת 0.25.



b. For each bound (Chebyshev and Hoeffding seen in class) and for each epsilon ,plot the upper bound as a function of m.


c. Plot the percentage of sequences that satisfy the equation as a function of m. What are you expecting to see in these plots?

ex1 IML



באי שייון בודקים האם המרחק בין התוחלת המשוערת לבין התוחלת האמיתית גדול מ- ϵ פסילון. הבדיקה נזקפת אם המשוערת אמת כמות השורות שמספקות את האי שייון חלקית כמות השורות בסך הכל - קלומר אחוז השורות שהמשוער טעה מעבר לטעות שהיינו מוכנים לקבל.

ניתן לבדוק בכך כי ככל שכמות הדגימות גדלה יותר ככל שורות ה"רעות" קטן, וזה אכן מתישב עם המציאות.

בנוסף לכך אפסילון משפיע על הערך של החסמים של צ'ביצ'ב והופידינג על ההסתברות שהמרחק בין הממוצע המשוער לבין הממוצע האמיתי גדול מ- ϵ פסילון. ככל שאפסילון קטן יותר (או דורותים דיוק רב יותר) הערך של המכנה קטן יותר וכשמחלקים במספר קטן התוצאה גדלה. לכן עבור אפסילון מאוד קטן (קלומר אם מרשימות טעות מזערית) נקבל חסם פחות הדוק. ולמעשה ככל שהאפסילון גדול יותר ככל שדרשות פחות דגימות כדי להגיע לאחוז מזערי של שורות "רעות". זה מסתדר גם מבחינת החסם (מתמטית) וגם מבחינת ההיגיון.



ex1 IML



ex1 IML

