

Ex2 IML  
Linear Regression

Let  $X$  be the design matrix of a linear regression problem with  $p$  rows (variables) and  $n$  columns (samples) in  $\mathbb{R}^p$ .  
Recall that for some vector space  $V \subseteq \mathbb{R}^p$  the orthogonal complement of  $V$  is  $V^\perp = \{x \in \mathbb{R}^p : \langle x, v \rangle = 0 \forall v \in V\}$

1) Prove that  $\ker(X^\top) = \ker(XX^\top)$

$$\ker(X^\top) = \{v \in V : X^\top v = 0\}$$

$$\ker(XX^\top) = \{v \in V : XX^\top v = 0\}$$

$$X^\top v = 0 \quad \text{sgc } v \in \ker(X^\top) \quad \text{sgc } v \in V \quad \text{(I)}$$

$$(X^\top v = 0 \quad \text{sgc } v \in \ker(X^\top)) \quad XX^\top v = 0 \quad \text{sgc } v \in \ker(XX^\top)$$

$$XX^\top v = 0 \quad \text{sgc } v \in \ker(XX^\top) \quad \text{sgc } v \in V \quad \text{(II)}$$

$$\therefore X^\top v = 0 \quad \text{sgc } X^{-1} X^\top v = 0 \quad \text{sgc } v \in \ker(X^\top)$$

$$\langle XX^\top v, v \rangle = 0 = \langle X^\top XX^\top v, v \rangle = \langle X^\top v, X^\top v \rangle = \langle X^\top v, v \rangle = 0$$

$$\ker(X^\top) \subseteq \ker(XX^\top) \quad \text{sgc } \ker(XX^\top) \subseteq \ker(X^\top)$$

$$\ker(X^\top) = \ker(XX^\top) \quad \text{sgc } \ker(XX^\top) \subseteq \ker(X^\top)$$

2) Prove that for some square  $A$ :  $\text{Im}(A^\top) = \ker(A)^\perp$

$$\text{Im}(A^\top) = \{\omega \neq 0 \in W : \omega = A^\top v, v \in V\}$$

$$\ker(A)^\perp = \{x \in \mathbb{R}^p : \langle x, v \rangle = 0 \quad \forall v \in \ker(A)\}$$

$$\ker(A) = \{v \in V : Av = 0\}$$

$$\omega \neq 0 \quad \text{sgc } v \in V \quad \text{sgc } \omega = A^\top v \quad \text{sgc } \omega \in \text{Im}(A^\top) \quad \text{sgc } \omega \in \text{Im}(A^\top) \quad \text{(I)}$$

$$\iff Av = 0 \quad \text{sgc } v \in \ker(A) \quad \text{sgc } v \in \ker(A)$$

$$\langle \omega, v \rangle = \langle A^\top v, v \rangle = V^\top(A^\top v) = V^\top A^\top v = (Av)^\top = 0^\top = 0 \cdot v = 0$$

$$\omega \in \ker(A)^\perp \quad \text{sgc } \langle \omega, v \rangle = 0 \quad \text{sgc } v \in \ker(A) \quad \text{sgc } \omega \in \ker(A)^\perp$$

$$\omega \in \ker(A)^\perp \iff \omega \in \text{Im}(A^\top) \quad \text{sgc } \text{Im}(A^\top) \subseteq \ker(A)^\perp \quad \text{sgc } \omega \in \text{Im}(A^\top)$$

$$\langle \omega, v \rangle = 0 \quad \text{sgc } v \in \ker(A) \quad \text{sgc } \omega \in \ker(A)^\perp \quad \text{(II)}$$

$$(Av)^\top = V^\top \omega \iff Av = 0 \quad \text{sgc } V^\top \omega = 0 \iff$$

$$\omega = A^\top v \iff A^\top \cdot (\cdot) = \omega \iff A^\top = \omega \iff V^\top A^\top = V^\top \omega \iff$$

$$\omega \in \text{Im}(A^\top) \iff$$

$$\ker(A)^\perp \subseteq \text{Im}(A^\top) \quad \text{sgc } \ker(A)^\perp \subseteq \text{Im}(A^\top)$$

אנו הוכיחו כי  $\ker(A)^\perp \subseteq \text{Im}(A^\top)$  וכן  $\text{Im}(A^\top) \subseteq \ker(A)^\perp$ .

3) Let  $y = X^T w$  be a non-homogeneous system of linear equations. Assume that  $X^T$  is square and not invertible. Show that the system has  $\infty$  solutions  $\Leftrightarrow y \perp \ker(X)$

הוכיחו ש-  $\dim(\text{Ker}(X^t)) \neq 0$  (ולכן  $X^t$  אינו מושם)

$$\text{ker } (X^T) = \{ v \in V ; X^T v = 0 \}$$

רעל (ג) X נסעה תרמלה ועם ג' כוותה

$$\text{Im}(X) = \{0 = \omega \in W : \text{ there exists } v \in V \text{ such that } Xv = \omega\} \quad (\text{I})$$

$$y \in \text{Im}(X^T) \iff y \in \text{Ker}(X)^{\perp} \quad \text{p.f.}$$

$$y \in \text{Im}(X^T) \cap y \in \text{Ker}(X)^{\perp} \iff y \perp \text{Ker}(X) \quad \text{בנוסף } \text{Im}(X^T) = \text{Ker}(X)^{\perp} \iff \text{Im}(X^T) \subseteq \text{Ker}(X)^{\perp}$$

$w \in V$  ו-  $y = x^T w$  נורא  $\Leftrightarrow$   $x$  מינימיזיר  $y$

$\text{Im}(X)$  כילה ביצה  $\leftarrow$  גבורה כטורה ו- $\text{Im}(Y)$  סכום של מטרים

4) Consider the normal linear system  $XX^T w = Xy$ . Using what you have proved above, prove that the normal equations can only have a unique solution if  $X^T X$  is invertible or infinitely many solutions.

Normal Equations are  $Xy = X X^T \omega$

$$(XX^T)^{-1}XY = \omega \quad \text{using } (XX^T)^{-1}X = X^{-1}X^T \text{ and } XX^T = \omega I$$

(I)

בנוסף לכך ( $\text{dim } \text{Ker}(X)$ )  $Xy \perp \text{Ker}(X^T)$

לכן  $x$  מקיים  $xy \in \ker(X)$

$$v \in \ker(X) \text{ if and only if } Xv \in \ker(X)^\perp \iff Xv \perp \ker(X)$$

$\langle x, v \rangle = 0$  לכל  $v \in \text{ker}(x)$  גורם לכך ש

$$\langle x, v \rangle = y^T X^T v = y^T 0 = 0 \iff v \in \text{ker}(X)$$

מִלְבָד מִפְרַשׁ תְּמִימָה כְּנֶסֶת הַבָּיִת מִלְבָד מִפְרַשׁ תְּמִימָה כְּנֶסֶת הַבָּיִת

$$\begin{aligned}
 5) \quad a) \quad \text{הוכיח כי } P = P^T \text{ מתקיים במאlicity אינטגרלית}
 \\
 P &= \sum_{i=1}^k V_i V_i^T = V_1 V_1^T + V_2 V_2^T + \dots + V_k V_k^T \\
 &= (V_1^T)^T V_1^T + (V_2^T)^T V_2 + \dots + (V_k^T)^T V_k^T \\
 &= (V_1 V_1^T)^T + (V_2 V_2^T)^T + \dots + (V_k V_k^T)^T \\
 &= (V_1 V_1^T + V_2 V_2^T + \dots + V_k V_k^T)^T \\
 &= \left( \sum_{i=1}^k V_i V_i^T \right)^T = P^T
 \end{aligned}$$

(b) + (d) מוכיח כי  $P = P^2$  ב- $\mathbb{R}^n$

לעומת פונקציית הילך  $f(x_1, \dots, x_n)$  גתק העתקה

$$(d) P^2 = \sum_{i=1}^k V_i V_i^T \sum_{j=1}^k V_j V_j^T = \sum_{i=1}^k \sum_{j=1}^k V_i V_i^T V_j V_j^T$$

$$= \sum_{i=1}^k \sum_{j=1}^k V_i < V_j, V_i > V_j^T = \sum_{i=1}^k \sum_{j=1}^k V_i \delta_{ij} V_i^T$$

$$= \sum_{i=1}^k V_i V_i^T = P$$

(ב)  $i \neq j$   $\Rightarrow \delta_{ij} = 0$   
 (ג)  $i = j$   $\Rightarrow \delta_{ii} = 1$

$$\langle V_i, V_j \rangle = \begin{cases} 1 \\ 0 \end{cases}$$

$\delta_{ij} = f_{ij}$

$$P^2x = P(Px) = P(\lambda x) = \lambda Px = \lambda x$$

$$P^2 \chi = P(P\chi) = P(\lambda \chi) = \lambda P\chi = \lambda^2 (\lambda \chi)$$

$$\lambda x = \lambda^* x \Rightarrow \lambda x(1-\lambda) = 0 \quad \mu$$

$$\lambda_0 = 0 \quad \lambda_1 = \frac{2\pi}{L} \quad \text{on } P \quad k = 2\pi/L \quad m_0 =$$

$$PV_j = \sum_{i=1}^K V_i V_i^\top V_j = \sum_{i=1}^K V_i \langle V_j, V_i \rangle = \sum_{i=1}^K V_i d_{i,j}$$

$$= \begin{cases} V_i & i=j \\ 0 & \text{else} \end{cases}$$

$M = \begin{bmatrix} I_{K \times K} & 0 \\ 0 & 0 \end{bmatrix}$  נורמליזציה של מטריצה  $A$  ביחס ל- $\|A\|_F$

00.10 ינ' מילון העממי ועכבר קבוצת מילים במקורה ערבית ובערבית. תרגום  
בנוסף ל-1 מילון עברי-ערבי.

000 (בנ"ה) (בנ"ה) (בנ"ה) (בנ"ה) (בנ"ה) (בנ"ה) (בנ"ה) (בנ"ה)

(c)

$$Pv = v \quad \text{প্রমাণ করুন } v \in V \quad \text{বিন্দু } v$$

$$a_j \quad \begin{matrix} \text{প্রমাণ করুন } \\ 1 \leq j \leq n \end{matrix} \quad v = \sum_{j=1}^n a_j v_j \quad \Rightarrow \quad v \in V \quad \text{প্রমাণ}$$

$$\begin{aligned} Pv &= \sum_{i=1}^k v_i v_i^\top v = \sum_{i=1}^k v_i v_i^\top \sum_{j=1}^n a_j v_j = \sum_{i=1}^k \sum_{j=1}^n a_j v_i v_i^\top v_j \\ &= \sum_{i=1}^k \sum_{j=1}^n a_j v_i \langle v_j, v_i \rangle = \sum_{i=1}^k \sum_{j=1}^n a_j v_i \delta_{ij} \\ &= \sum_{i=1}^k a_i v_i = v \quad \Rightarrow \quad Pv = v \end{aligned}$$

(d)

$$\begin{aligned} v &= a+b \quad 0,1 \text{ পদ শুনো পরে } P=P^2 \quad -e \text{ হোলি করুন} \\ P^2 v &= P^2(a+b) = P(P(a+b)) = P(Pa+Pb) = P(0+b) \\ (e) \quad P^2 &= P \quad \Leftrightarrow \quad P = P^2 \quad \Leftrightarrow \quad P(I-P) = 0 \quad \Leftrightarrow \quad (I-P)P = 0 \end{aligned}$$

(c) Assume  $XX^T$  is invertible

Show that  $(XX^T)^{-1} = UD^{-1}U^T$  where  $D = \Sigma\Sigma^T$   
Use this to show that  $(XX^T)^{-1}X = X^T$

then  $(XX^T)^{-1}$  has inverse  $\Rightarrow$   $XX^T$  is invertible

$$X = U \Sigma V^T$$

from which we know  $\Sigma\Sigma^T$  is invertible

$$XX^T = U\Sigma V^T (V\Sigma^T U^T)$$

$$= U\Sigma V^T V\Sigma^T U^T$$

$$\text{from which } V = U\Sigma I \Sigma^T U^T$$

$$= UD^T U^T$$

$$(XX^T)^{-1} = UD^{-1}U^T$$

$$XX^T (XX^T)^{-1} = I$$

$$UD^T U^T UD^{-1} U^T = UD I D^{-1} U^T$$

$$= UDD^{-1}U^T = U^T U^T = I$$

$$(XX^T)^{-1}X = X^T$$

$$\Sigma^T_{ii} = \begin{cases} \frac{1}{\Sigma_{ii}} & \Sigma_{ii} \neq 0 \\ 0 & \text{else} \end{cases}, \quad X^T = (V\Sigma U^T)^T = V\Sigma^T U$$

$$(XX^T)^{-1}X = UD^{-1}U^T U\Sigma V^T$$

$$UD^{-1}U^T = UD^{-1}\Sigma V^T$$

from which  $\Sigma$

$$\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} & 0 \\ \Sigma_{21} & \Sigma_{22} & 0 \\ \Sigma_{K1} & \Sigma_{K2} & \ddots \\ 0 & 0 & 0 \end{pmatrix} = \begin{pmatrix} \Sigma_{KK} & 0 \\ 0 & 0 \end{pmatrix}$$

$$\Sigma^T = \begin{pmatrix} \Sigma_{11} & \Sigma_{21} & 0 \\ \Sigma_{12} & \Sigma_{22} & 0 \\ \Sigma_{K1} & \Sigma_{K2} & \ddots \\ 0 & 0 & 0 \end{pmatrix} \Rightarrow (\Sigma\Sigma^T)^T = (\Sigma^2)^T$$

$$UDV^T V\Sigma^T U^T \leftarrow \text{הכרה}$$

$$\text{הכרה} \rightarrow U\Sigma^2 U^T \leftarrow$$

$$\Sigma^2 = \Sigma \Sigma^T \rightarrow \text{בנוסף}$$

$$D^{-1} = \begin{pmatrix} \frac{1}{\Sigma_{11}^2} & & \\ & \frac{1}{\Sigma_{22}^2} & \\ & & \frac{1}{\Sigma_{nn}^2} \end{pmatrix} \rightarrow \text{בנוסף}$$

$$D^{-1} = (\Sigma \Sigma^T)^{-1} + \left( \frac{1}{\Sigma_{11}^2} \right) \left( \frac{1}{\Sigma_{22}^2} \right) \cdots \left( \frac{1}{\Sigma_{nn}^2} \right)$$

$m > n$  ומכאן  $D^{-1}$  מושג בז'ר

$$(X X^T)^{-1} X = U \begin{pmatrix} \frac{1}{\Sigma_{11}^2} & & \\ & \frac{1}{\Sigma_{22}^2} & \\ & & \frac{1}{\Sigma_{nn}^2} \end{pmatrix} \begin{pmatrix} \Sigma_{11} & & & \\ & \Sigma_{22} & & \\ & & \ddots & \\ & & & \Sigma_{nn} \end{pmatrix} \begin{pmatrix} 0 & & & \\ & 0 & & \\ & & \ddots & \\ & & & 0 \end{pmatrix}_{n \times m-r}$$

$$\bullet V^T = U \begin{pmatrix} \frac{1}{\Sigma_{11}^2} & & 0 & \\ & \frac{1}{\Sigma_{22}^2} & & 0_{n \times n} \\ & & \ddots & \\ & & & \frac{1}{\Sigma_{nn}^2} \end{pmatrix}_{m \times n} V^T$$

$$= U \Sigma^{T+} V^T$$

$$D^{-1} \Sigma = \Sigma^+$$

$$(X X^T)^{-1} X = U D^{-1} \Sigma V^T$$

$$= U \Sigma^+ V^T = X^+$$

7)  $\text{rank}(XX^\top) = d \iff \text{הטלה חילICA}, \quad XX^\top \in \mathbb{R}^{d \times d}$

$$\begin{aligned}\text{הטלה חילICA} &\Rightarrow \text{הטלה חילICA} \\ \text{rank}(XX^\top) &= \dim(\text{Im}(XX^\top)) \\ \text{rank}(X) &= \dim(\text{Im}(X))\end{aligned}$$

$\{x_1, \dots, x_m\}$  במרחב  $\mathbb{R}^n$  תולב  $X$  ב-  $\mathbb{R}^d$

$$\text{Span}\{x_1, \dots, x_m\} = \mathbb{R}^d \iff \text{rank}(X) = d = \dim(\text{Im}(X))$$

מכאן

$$\dim(\text{Im}(XX^\top)) = d \iff \text{rank}(XX^\top) = d \iff \text{הטלה חילICA } XX^\top$$

$$\dim(\ker(X^\top)) = 0 \iff \dim(\ker(XX^\top)) = d - d = 0 \iff$$

$$\text{הטלה חילICA} \iff \text{rank}(X^\top) = d \iff \dim(\text{Im}(X^\top)) = d - 0 = d \iff$$

$$\text{Span}\{x_1, \dots, x_m\} = \mathbb{R}^d \iff \text{rank}(X) = d$$

8)  $XX^\top \bar{\omega} = xy$  normal equation -> היכן קורא  $\bar{\omega}$  "

$$(XX^\top)^{-1} XX^\top \bar{\omega} = (X^\top X)^{-1} Xy \quad \text{היכן קורא } XX^\top \text{ נורמל} \quad (\text{I})$$

$$\bar{\omega} = (XX^\top)^{-1} Xy = X^{-1} X^\top y = \hat{\omega} \quad \text{היכן קורא } \hat{\omega}$$

$$\|\bar{\omega}\|_2 = \|\hat{\omega}\|_2 \quad \text{pls}$$

$$\|\hat{\omega}\|^2 = \sum_{i=1}^d \hat{\omega}_i^2 = \sum_{i=1}^r \hat{\omega}_i^2 + \sum_{i=r+1}^d \hat{\omega}_i^2 = \sum_{i=1}^r \hat{\omega}_i^2 + 0 \quad (\text{II})$$

$$= \sum_{i=1}^r \bar{\omega}_i^2 \quad \begin{array}{l} \hat{\omega}_i = 0 \quad r+1 \leq i \leq d \text{ בפ} \\ \hat{\omega}_i = \bar{\omega}_i \quad 1 \leq i \leq r \text{ בפ} \end{array} \quad \begin{array}{l} XX^\top \bar{\omega} = xy \quad \text{היכן קורא } \bar{\omega} \text{ נורמל} \\ \text{חישוב} \end{array}$$

$$\leq \sum_{i=1}^r \bar{\omega}_i^2 + \sum_{i=r+1}^d \bar{\omega}_i^2 = \sum_{i=1}^d \bar{\omega}_i^2 = \|\bar{\omega}\|^2$$

$r = \text{rank}(X) < d$  "היכן קורא  $XX^\top$  נורמל נורמל"

## Iml Ex2

### 13.

- In your submitted PDF explain what were the features you found to be categorical.

בתרגום מוסבר כי מעתנים קטגוריאליים הם פיצרים שאין סדר הגינוי לערכיהם שלם מבובן שאין משמעות לזה שאחד גדול מהשני. אנו בודקים את המשמעות של אותו פיצר מול ה **response vector** שהוא המחיר, כלומר כיצד ישפיע המחיר על המחיר. אכן מיקום עשוי להשפיע על פרדיקציה של מחיר הדירה שכן יש מיקומים יקרים, אול' קרובים לים או לאורק שמעלה את המחיר. אולם המיקוד מבחינת הערך המספרי שלו לא נותן אינפורמציה שתושפיע על המחיר. בית עם מיקוד ח לא בהכרח יהיה זול יותר מבית במיקוד 1+ח, לעומת הגודל של המספר לא משפיע. מכאן שאין קשר לינארי בין גודל במיקוד לבין המחיר, ולכן זהו משתנה שעל פי הגדרה **קטגוריאלי**.

### 14+15.

14. Implement a function called ‘plot\_singular\_values‘ that receives a collection of singular values and plots them in descending order. That is: x-axis a running index number and y-axis the singular value’s value. This kind of plot is called a scree-plot.

**Describe what can be learned from the singular values.**

נשים לב להסביר מתוך התרגול:

$A : \mathbb{R}^d \rightarrow \mathbb{R}^m$  (matrix  $A \in M_{m \times d}(\mathbb{R})$ ) admits a singular value decomposition of the form:

$$A = U\Sigma V^\top$$

which means that  $A(w)$  actually does the following:

1. rotation of  $w$  (multiply by orthogonal matrix  $V^\top$ ).
2. stretch the rotated vector (multiply by diagonal matrix  $\Sigma$ ).
3. apply another rotation to the stretched vector (multiply by orthogonal matrix  $U$ ).





Figure 3: SVD intuition

כלומר המטריצה האלכסונית (על האלכסון מצויים הערכים הסוגוריים) אחראית על המתיחה.

מכאן שבפרק SVD הערכים הסינגולריים ישפיעו על המתייחס ולמעשה ישפיעו על המשקל של כל פיצ'ר שחשבנו על מנת לחזות מהו המחיר בהינתן פיצ'רים.



למעשה ככל שהערך הסינגולרי גדול יותר כך מידת ההשפעה על המחיר של אותו פיצ'ר, שמתאים לערך הסינגולרי, תהיה גדולה יותר.

כמו כן, ככל שהערכים הסינגולריים קטנים יותר קיימת תלות בין הפיצ'רים המתאימים להם. יש לנו מעט ערכים סינגולריים גדולים, והשאר קרובים ל-0, כך שהמטריצה ניתנת לייצוג במימד נמוך יותר. כמות החדרים וגודל הדירה משפיעים במידה רבה על המחיר, אך ההשפעה היא במידה אחרת.

### Is the design matrix ( $X$ ) close to being singular or not?

נתבונן בערכים הסינגולריים:

ונבחין כי ישנו ערך  $-10^{13} \cdot 10^{-2.78}$ .

מכאן שהמטריצה כמעט סינגולרית (הערך אינו 0 אך מאוד קרוב ל-0).

**Definition 6.** Let  $A \in \mathbb{R}^{n \times n}$  be a square matrix.  $A$  is called invertible (or non-singular) if there exists a matrix  $B \in \mathbb{R}^{n \times n}$  such that  $AB = I_n = BA$ . We denote  $A$ 's inverse by  $A^{-1}$ .

למדנו כי מטריצה סינגולרית היא מטריצה שאין לה הופכית, כאשר בפרק SVD אם במטריצה האלכסונית קיים ערך סינגולרי שהוא 0 אז היא לא הפיכה ובהתאם המטריצה שלה בצענו פירוק.


הערכים הסינגולריים שהציגנו מופיעים על אלכסון המטריצה האלכסונית, כך שאם אחד מהם הוא 0, היה לא הפיכה ولكن סינגולרית.

```
[2.96002536e+09 6.84653975e+06 2.47573993e+06 1.90644171e+05
 7.74035145e+04 5.81938652e+04 8.15367369e+03 3.72533296e+03
 1.16840223e+02 1.01544634e+02 9.57995510e+01 8.77627322e+01
 6.86982942e+01 5.20182591e+01 2.77800538e+01 2.41983198e+01
 2.39471879e+01 2.38439049e+01 2.37372232e+01 2.32513301e+01]
```

2.29386432e+01 2.28751631e+01 2.22151595e+01 2.21473020e+01  
 2.16477090e+01 2.16382584e+01 2.14344112e+01 2.11177092e+01  
 2.08274306e+01 2.06521048e+01 2.04891164e+01 2.00903785e+01  
 1.99575984e+01 1.98373026e+01 1.94706516e+01 1.87285912e+01  
 1.87001881e+01 1.86073001e+01 1.83535942e+01 1.82075088e+01  
 1.81254274e+01 1.77845556e+01 1.76432698e+01 1.74950469e+01  
 1.69762785e+01 1.68878070e+01 1.67942833e+01 1.67731572e+01  
 1.67286317e+01 1.66010025e+01 1.65414575e+01 1.64966113e+01  
 1.64091676e+01 1.63109383e+01 1.62343031e+01 1.62050557e+01  
 1.61337494e+01 1.60701726e+01 1.59652342e+01 1.56658969e+01  
 1.54764730e+01 1.50586254e+01 1.49139710e+01 1.44846981e+01  
 1.43829571e+01 1.39775714e+01 1.38092132e+01 1.37552995e+01  
 1.35000640e+01 1.32485493e+01 1.29037860e+01 1.20309997e+01  
 1.19297532e+01 1.17822418e+01 1.11992784e+01 1.09346425e+01  
 1.04323191e+01 1.01867896e+01 1.01016386e+01 9.83462855e+00  
 8.95093478e+00 7.91702189e+00 7.15769055e+00 6.79298100e+00  
 1.70861561e+00 5.33330065e-11 **2.78716840e-13]**

## 16.

- Add to your answers PDF the plot of the MSE over the test set as a function of  $p\%$ .
- Explain the results you got.




אנו מחשבים את השגיאה הריבועית הממוצעת, ובודקים עד כמה טעינו בניתוח.

כלומר אנו מקבלים מטריצת פיצרים ובעזרתה מנוטים לנחש מה המחיר של הבית, נרצה לבדוק עד כמה הניחוש שלנו היה טוב.


נעשה זאת על ידי קר שנשווה בין הפרדיקציה לבין המחיר האמיתי. הבדיקה תבצע חיתוך של הדאטה test set training set ולפניהם נבדוק את השגיאה על test set. הבדיקה תבצע חיתוך של הדאטה training set test set ולפניהם נבדוק את השגיאה על test set. בכל איטרציה האחוז של הדאטה שנדגם גדול ככלנו חישוב המשקלים על כמות יותר גדולה של דאטה. ככל שהדאטה גדול יותר קר נצפה לקבל תוצאה מדויקת יותר וקרובה יותר למציאות. רואים שהחול מ-60% אנחנו נשאים די יציבים מבחינת השגיאה עד שמכסים את כל training set. ובאופן יחסי רואים ירידה בשגיאה ככל שהאחוז גדול.

- כמו כן, אני מוסיפה את התוצאות שהתקבלו כאשר הורדתי לחלוון את הפיצר של הדאטה: פונקציית `msnm` נראה שהיא מסדר גודל שנה מאוד קטן -  $10^{-21}$



```
[6.47588522e+06 4.80970692e+05 9.70783222e+04 7.74043545e+04
 1.22007344e+02 1.04505530e+02 1.02724317e+02 9.26438524e+01
 7.34482709e+01 5.30185097e+01 2.95051535e+01 2.42264695e+01
 2.39762866e+01 2.38854589e+01 2.37539135e+01 2.32846233e+01
 2.31665312e+01 2.29866194e+01 2.23738408e+01 2.22343961e+01
 2.19101935e+01 2.17605809e+01 2.14780562e+01 2.12187942e+01
 2.08923521e+01 2.08348742e+01 2.05082716e+01 2.01674006e+01
 2.01114179e+01 1.98534506e+01 1.95126852e+01 1.89176511e+01
 1.87573700e+01 1.86834064e+01 1.84018201e+01 1.83365365e+01
 1.81544323e+01 1.78340978e+01 1.76934510e+01 1.75348047e+01
 1.70546445e+01 1.68922913e+01 1.68401130e+01 1.67808558e+01
 1.67688174e+01 1.67047845e+01 1.66300495e+01 1.65204014e+01
 1.64695914e+01 1.63873774e+01 1.63293966e+01 1.62180526e+01]
```



1.62095271e+01 1.60933275e+01 1.59741773e+01 1.58003262e+01  
 1.57364883e+01 1.56951754e+01 1.51591119e+01 1.49974323e+01  
 1.47021949e+01 1.41820308e+01 1.39672953e+01 1.38530351e+01  
 1.37709442e+01 1.35665796e+01 1.33932920e+01 1.28607010e+01  
 1.19842500e+01 1.18271294e+01 1.16783012e+01 1.11947717e+01  
 1.09841740e+01 1.04662501e+01 1.02190310e+01 1.00510142e+01  
 9.93735481e+00 8.87942877e+00 7.58459844e+00 7.04506238e+00  
 2.08924559e+00 1.28680969e+00 **1.19979102e-10**



## 17.


Choose two features, one that seems to be beneficial for the model and one that does not.  
 In your answers PDF add the graphs of these two chosen features and explain how do you conclude if they are beneficial or not.

נתבונן כיצד הציון משפיע על המחיר :  
 נשים לב כי הקורלציה של פירסון הינה ממד לקשר לינארי בין משתנים ובמקרה זה היא בעלת ערך גובה 0.67  
 ומכאן ניתן להסיק כי קיימם קשר לינארי בין הציון למחיר הבית.  
 כמו כן ניתן לראות כי ככל שהציון גבוהה יותר כך גם המחיר גבוה יותר.





כאשר במקורה זה ניתן לראות כי מתאם פירסון הינו גובה - 0.7 ומצדיק את הקשר הלינארי בין גודל הדירה לבין המחיר. ככל שהדירה תהיה גדולה יותר כך המחיר עבורה יהיה גבוה יותר, דבר שתואם את הממציאות.

התנאים הם בעצם אינדקסים מ-1 עד 5 על התנאים בדירה.  
אנו רואים מוקדם פירסון נמוך מאוד ולכן הקשר הלינארי בין התנאים בדירה למחיר הינו מצער.  
ניתן לראות שלא בהכרח ככל שהאינדקס גדול יותר כך המחיר גדול יותר.



נתבון כיצד משפיעה השנה שבה נבנה הבניין על המחיר:  
אנו רואים כי על פי מתאם פרטן ההתאמה היא מזערית כלומר המדד קשר הילינארי בין שנת הבניה למחיר  
הוא מועט.  
כך שבתים שנבנו לפני מאה שנה לא בהכרח יותר זולים מבתים חדשים.








במקרה זה דוקא ניתן לראותות כי מתאם פרטון נמור

יחסית כך שהמדד לקשר הלינארי בין מחיר לבין האם הדירה משקיפה לכך החוף אינו גבוה. נתון קצת מפתיע עיניים שכן קרובה לחוף לפחות בישראל מuplicה את מחירי הבתים.


עוד דוגמאות מעניינות הן הקשר בין מספר חדרי השינה, גודל המרתף ומספר הקומות למחיר : שוב מדובר בקשר לינארי פחות חזק מדוגמאות שראינו כמו גודל הדירה והצינן שלה.






21. Plot two graphs: the first is the "log\_detected" as a function of "day\_num", and the second is "detected" as a function of "day\_num". On each graph, add the data as single points, and add the fitted curve that you've estimated (think how to convert the linear result into an exponential result). Add those graphs to your answers PDF.

detected as a function of day num



log\_detected as a function of day num



## 22.

از כמו שניתן לראות בשאלת 21 :  
כאשר הצגנו את מספרים המקוריים של קורונה שזוהו כפונקציה של מספר הימים שעברו מאז שזיהו את הבדיקה הראשונה בישראל קיבלנו כי ה- fitted model הינו גרפ אקספוננציאלי.  
במה שסביר כיצד עשינו זאת.  
לעומת זאת כאשר הצגנו את log מספרים המקוריים של קורונה שאובחנו כפונקציה של מספר הימים שעברו קיבלנו כי ה- fitted model הינו גרפ לינארי.

Exponential Growth is a mathematical function that can be used in several situations. The formula tells us the number of cases at a certain moment in time, in the case of Coronavirus, this is the number of infected people.

### The formula of Exponential Growth

Exponential Growth is characterized by the following formula:

$$x(t) = x_0 * b^t$$

The Exponential Growth function

In which:

- $x(t)$  is the number of cases at any given *time t*
- $x_0$  is the number of cases at the beginning, also called *initial value*
- $b$  is the number of people infected by each sick person, the *growth factor*

Linear Regression allows us to estimate the best values for a and b in the following formula, given empirical observations for y and x. In this formula, y is the number of cases and x is the time. But we need to do some rewriting on the Exponential Growth function, because Linear Regression can only estimate formulas that look as below:

$$y = a + b * x$$

The type of formula that we need for Linear Regression

$$\begin{array}{c} y = a + b * x \\ \leftrightarrow \\ \log x(t) = \log(x_0) + \log(b) * t \end{array}$$

- we use the **log of the number of infections** instead of the **number of infections**
- we use the **log of growth factor** instead of **growth factor**

ואז נעשה fit על המודל הליינארי נקבל את a,b וначלץ את ה-growth-factor, initial value

$$22) \quad L_{\text{exp}}(f(w), (xy)) = (\langle w, x \rangle + \log y)^2$$

האנו מודדים את ה

### loss function

 (פונקציית האפס-הממשת)  $\ell(y - \hat{y})$  (ה

### least squares loss

 - פונקציית האפס-הממשת מינימלית) בהמודל  $y = f(x)$ .

$$y = A e^{Bx} \rightarrow \log y = \log A + Bx$$

$$S_r = \sum_{i=1}^n (y_i - A e^{B x_i})^2$$

$$\frac{\partial S_r}{\partial B} = \sum_{i=1}^n 2(y_i - A e^{Bx_i})(-A x_i e^{Bx_i}) = 0$$

$$\Rightarrow - \sum_{i=1}^n y_i e^{Bx_i} + A \sum_{i=1}^n e^{2Bx_i} = 0$$

$$\sum_{i=1}^n y_i x_i e^{Bx_i} - A \sum_{i=1}^n x_i e^{Bx_i} = 0$$

$$\ln y = \ln A + \ln(e^{Bx}) = \ln A + Bx$$

$$Z = A_0 + A_1 X \quad \text{בנוסף } A_1 = B, Z = \ln y, A_0 = \ln A \quad \text{ונז}$$

$A_0, A_1$  נסוברים מנגנון הפעלה של ביצועים, ו $B$  מושג מנגנון

$A_0$  :  
'הנורם'  $B = A'$  נסוברים מנגנון

$$\theta = e \quad B = A_1$$

$$a_1 = \frac{n \sum_{i=1}^n x_i z_i - \sum_{i=1}^n x_i \sum_{i=1}^n z_i}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2} ; \text{ linear model regression } n \times n \text{ no } 0 \text{ and } 1$$

$$a_0 = \bar{z} - a_1 \bar{x}$$

$$\text{ERM problem: } \arg \min_{\omega \in \mathbb{R}^d} \|X^\top \omega - y\|^2 = \arg \min_{\omega} \frac{1}{n} \sum_{i=1}^n (x_i^\top \omega - y_i)^2$$

בכדי זה נקבעים  $y = A e^{kt}$  ו-  $y = B e^{-kt}$

רְגִזְגִּזְמָנִים-n least-square-n לְעֵינָהוּ מִתְּבָאָה כַּלְבָּד וְלֹא  
אֶתְּנָאָה כַּלְבָּד כַּאֲשֶׁר בְּכָלְבָּד כַּלְבָּד

$\beta_0 = \log d$  intercept on  $t$  to  $\log y$  axis  $\log y = \log d + \beta t$

least squares and is  $Z = \log y$  fit (1)