

Shelly Gamliel

INAL Ex 4

הוכיחו ב- ϵ -הגדרה, שקיים סדרת גיבובים $A_{(s)}$ כך ש- $b - a \leq \epsilon$:

$$a) \quad \mathbb{P}_{SND^m} [L_b(A_{(s)}) \leq \epsilon] \geq 1 - \delta$$

$$b) \quad \lim_{m \rightarrow \infty} \mathbb{E}_{SND^m} [L_b(A_{(s)})] = 0$$

$$b \Leftarrow a$$

$$\mathbb{P}_{SND^m} [L_b(A_{(s)}) \leq \epsilon] \geq 1 - \delta$$

$$\mathbb{P}_{SND^m} [L_b(A_{(s)}) \leq \epsilon] \geq 1 - \delta \iff \mathbb{P}_{SND^m} [L_b(A_{(s)}) > \epsilon] \leq \delta$$

$$\mathbb{P}_{SND^m} [L_b(A_{(s)}) > \epsilon] \leq \mathbb{E}_{SND^m} \frac{[L_b(A_{(s)})]}{\epsilon}$$

$$m > m' \text{ בז } \Rightarrow m > 0 \text{ ו } \epsilon' > 0 \text{ בז } \text{הוכחה גב}$$

$$\mathbb{E}[L_b(A_{(s)})] = |\mathbb{E}[L_b(A_{(s)})]| < \epsilon'$$

$$\epsilon = \delta = \min\left\{\frac{1}{2}, \frac{\epsilon'}{2}\right\}, \quad m' = m(\epsilon, \delta) \text{ מכוון}$$

$$\epsilon = \delta = \frac{1}{2} \quad \text{וכי } 1 < \epsilon' \iff \frac{1}{2} < \frac{\epsilon'}{2} \quad \text{וכי}$$

$$\epsilon = \delta = \frac{\epsilon'}{2} \quad \text{וכי } 1 \geq \epsilon' \iff \frac{1}{2} \geq \frac{\epsilon'}{2} \quad \text{וכי}$$

$$\mathbb{E}_{SND^m} [L_b(A_{(s)})] \leq \mathbb{P}_{SND^m} [L_b(A_{(s)}) > \frac{1}{2}] \cdot 1 + \mathbb{P}_{SND^m} [L_b(A_{(s)}) \leq \frac{1}{2}] \cdot \frac{1}{2}$$

$$\leq \mathbb{P}_{SND^m} [L_b(A_{(s)}) > \frac{1}{2}] + 1 \cdot \frac{1}{2} \quad \text{פונקציית כב}$$

$$= \mathbb{P}_{SND^m} [L_b(A_{(s)}) > \frac{1}{2}] + \frac{1}{2} \leq \delta + \frac{1}{2} = \frac{1}{2} + \frac{1}{2} \leq 1$$

$$< \epsilon' \quad \Rightarrow \quad \mathbb{E}_{SND^m} [L_b(A_{(s)})] < \epsilon'$$

$$\mathbb{E}_{SND^m} [L_b(A_{(s)})] \leq \mathbb{P}_{SND^m} [L_b(A_{(s)}) > \frac{\epsilon'}{2}] \cdot 1 + \mathbb{P}_{SND^m} [L_b(A_{(s)}) \leq \frac{\epsilon'}{2}] \cdot \frac{\epsilon'}{2}$$

$$\leq \mathbb{P}_{SND^m} [L_b(A_{(s)}) > \frac{\epsilon'}{2}] + 1 \cdot \frac{\epsilon'}{2} \leq \delta + \frac{\epsilon'}{2} = \frac{\epsilon'}{2} + \frac{\epsilon'}{2} = \epsilon'$$

$$\Rightarrow \mathbb{E}_{SND^m} [L_b(A_{(s)})] < \epsilon'$$

$$\lim_{m \rightarrow \infty} \mathbb{E}_{SND^m} [L_b(A_{(s)})] = 0 \quad \text{וכי הוכחה כי}$$

$$\begin{aligned}
 E[L_b(A(s))] &= \int_{-\infty}^{\infty} L_b(A(s)) f(L_b(A(s))) ds \\
 \textcircled{*} &= \int_0^\epsilon L_b(A(s)) f(L_b(A(s))) ds = \int_0^\epsilon L_b(A(s)) f(L_b(A(s))) \\
 &+ \int_\epsilon^\infty L_b(A(s)) f(L_b(A(s))) ds \leq \epsilon \int_0^\epsilon f(L_b(A(s))) ds \\
 &+ 1 \cdot \int_\epsilon^\infty f(L_b(A(s))) ds = \epsilon (P(L_b(A(s)) \leq \epsilon) - P(L_b(A(s)) \geq \epsilon)) \\
 &+ \epsilon (P(L_b(A(s)) \leq \epsilon) - P(L_b(A(s)) \leq \epsilon)) \\
 &= \epsilon \cdot [P(L_b(A(s)) \leq \epsilon) - P(L_b(A(s)) \leq \epsilon)] + 1 - P(L_b(A(s)) \leq \epsilon) \\
 &= \epsilon \cdot [P(L_b(A(s)) \leq \epsilon) + P(L_b(A(s)) > \epsilon)] \\
 &\stackrel{\text{לפ' } L_b(A(s)) \in [0,1]}{=} \epsilon [F_x(\epsilon) - F_x(0)] = P(X \leq \epsilon) - P(X \leq 0)
 \end{aligned}$$

$a \uparrow b$

$$\lim_{m \rightarrow \infty} [E(L_p(A \cup I))] = 0$$

o più n'inciso euro

$$E_{\text{sum}} L_0(A(0)) = \left| E_{\text{sum}} L_0(A(0)) \right| < \varepsilon'$$

$$\Pr_{\text{SNDM}} [L_D(A(s)) \geq \varepsilon] \leq \mathbb{E}_{\substack{\text{SNDM} \\ s \in \mathcal{S}}} [L_D(A(s))] \quad (\text{by def})$$

לעתה נזכיר את $E = E/f$

$$\Rightarrow \underset{\text{snorm}}{P} [L_p(A(S)) \geq \varepsilon] < \delta$$

$$\Rightarrow \mathbb{P}_{\text{supp}(\mu)}[\text{ho}(A(\zeta)) \leq \varepsilon] \geq 1 - \delta$$

Sample Complexity of concentric circle in the Plane
 domain set $X = \mathbb{R}^2$, label set $Y = \{0, 1\}$
 $\text{hr. } r \in \mathbb{R}^+$


$$H = \{ h_r : r \in \mathbb{R}^+ \}$$

$m_{\text{H}}(\epsilon, \delta) \leq \frac{\log \frac{1}{\delta}}{\epsilon^2}$ Sample complexity, PAC bound in H : 13

לפיכך רצוי ש- C יהיה מוגדר כsubset של A , כלומר $C \subseteq A$.
 אם $C = \emptyset$ אז $\forall x \in C$ נובא $x \in A$, כלומר $\emptyset \subseteq A$.
 אם $C \neq \emptyset$ אז $\exists x \in C$ נובא $x \in A$, כלומר $C \subseteq A$.

$$\mathbb{P} [|D_{\ell,C}(C)| > \varepsilon] \leq \delta$$


בְּרֵבָד כִּי כַּאֲמָר בְּרֵבָד כִּי כַּאֲמָר




ג' (ג') תמיינט האנזה יונת לומד ב' הדרה מילר

כעת נסמן סעיפים (ר' $\leq \|x_i\| \leq r$) היפוכים ג' ו' מינימום ו' מינימום
היפוכם מינימום ג' ו' מינימום ג' ו' מינימום ג' ו' מינימום ג' ו' מינימום ג'

$\epsilon = n \log \frac{1}{\delta}$ for any $\delta > 0$. Then $T' = O(n^2)$ and $T' = O(n^2)$.



PET DIC
S-N DIC
IC T' DIC
T DIC DIC



$$T = \{x \in B^2; \hat{r} \leq \|x\| \leq r\}$$

\supset $\{x \in B^2; r^* \leq \|x\| \leq r\}$

$$D_x(\{x; \hat{r} \leq \|x\| \leq r\}) = \epsilon$$

\supset $\{x \in B^2; \hat{r} - \epsilon \leq \|x\| \leq r\}$

T' -> BINS OF T

T' \rightarrow BIV T'

רְאֵת יְהוָה בְּכָל־עַמּוֹת כִּי־בְּנֵי־יִשְׂרָאֵל - תְּבִיא אֶת־עֲמָקָם
תְּבִיא אֶת־עֲמָקָם תְּבִיא אֶת־עֲמָקָם תְּבִיא אֶת־עֲמָקָם

לכן אין לנו מושג מהי היחסים בין המושגים השונים ומי יתאפשר לארח את אחד מהם על השני.

$$\begin{aligned} P[|f_{0,c}(c') - \bar{c}| > \epsilon] &\leq (-\epsilon)^m \quad \text{using the same reasoning as above} \\ &\leq e^{-\epsilon m} \quad \text{from part (c)} \\ &\Leftrightarrow 1 - e^{-\epsilon} \leq e^{-\epsilon m} \end{aligned}$$

, $(1-\varepsilon)^m \leq \delta$ ניכר מהוועה מ- m מנייה דינמיות
בנוסף ל'היפוך' הנזכר מ- δ לעד $1-\varepsilon$ שנותרנו ב'היפוך' ε - δ מ- δ לעד $1-\varepsilon$.

VC dimension

Boolean Conjunction

$y = \{0,1\}$, $X = \{0,1\}^d$

$x_k, \bar{x}_k = 1 - x_k$; $D \subseteq \{0, 1\}^n$, $k \in [d]$, x_k הינה שורה ב- D אם ורק אם $\bigwedge_{i=1}^n x_i$ Boolean conjunction שתקיים. H היא היפר-פונקציית דרגה 2 על D .

Hcon @ VC dimenton : B

$$VCdim(H_{\text{con}}) = \sup \left\{ m \in \mathbb{N} : \exists C \text{ (with } |C|=m \text{ and } H \text{ shatters } C \right\}$$

בכל שורה הינה סדרה של נקודות על ישר. אם נסמן את נקודות ה- n -היה C_n , אז C_1, C_2, \dots, C_n ייצרו סדרה של נקודות על ישר.

כט) גודל ה-VC dim(Hom) = d ל. א. מ. גודל ה-VC

הנ'יך הגדין הוכן - א $\dim(C) \leq \dim(X)$ כיון $\dim(H^0(X, C)) \geq d$

הנ' $C = \{0, \dots, d\}$ ו $\forall i \in C$ $\exists j \in C$ $i \neq j$ $\text{such that } d_i = d_j$

$$h(l_i) = \bigwedge_{j \in I} \overline{x_j} \quad \text{if } (y_1, \dots, y_d) \in \{0,1\}^d \text{ and } l_i(y) = 0$$

$$h(e_1) = 0 \wedge 1 = 0 = y_1 \quad e_1 = (1, 0) \quad d=2 \text{ による 1 次元}$$

$$h(b) = \overline{x_2} = 0 \Rightarrow y_2 = 0, \quad (y_1, y_2) = (1, 0) \quad d=2$$

$$h(\ell_2) = \bar{x}_1 = y_1 = y_2 \quad \ell_2 = (0, 1) \quad d=2$$

$$(y_1, y_2) = (0, 1)$$

ההנחתה הינה ש $\bigwedge_{i \in I} x_i = 1$ מתקיימת אם ורק אם $I \neq \emptyset$ ו- $x_i = 1$ עבור כל $i \in [d]$.

$$h(e_i) = \bigwedge_{i \in I} x_i \quad \text{ר' } \Rightarrow \quad x_i \wedge \bar{x}_i = 0 \quad \text{ר' } \wedge$$

$$\begin{aligned} & y_j = 0 \quad \text{ר' } \Rightarrow \quad x_j \in \{0, 1\} \quad \text{ר' } \wedge \\ & x_i \wedge x_j = 0 \quad \text{ר' } \wedge \quad x_i \neq x_j \quad \text{ר' } \wedge \quad x_i \in \{0, 1\} \quad \text{ר' } \wedge \\ & \bar{x}_i \wedge \bar{x}_j = 0 \quad \text{ר' } \wedge \quad \bar{x}_i \neq \bar{x}_j \quad \text{ר' } \wedge \end{aligned}$$

$$\begin{aligned} & x_i = 1 \Rightarrow \bar{x}_i = 0 \quad \text{ר' } \wedge \quad x_i = 0 \Rightarrow \bar{x}_i = 1 \\ & \Downarrow \quad \Downarrow \\ & x_j = 0 \Rightarrow \bar{x}_j = 1 \quad \text{ר' } \wedge \quad x_j = 1 \Rightarrow \bar{x}_j = 0 \\ & \Downarrow \quad \Downarrow \\ & \bar{x}_i \wedge \bar{x}_j = 0 \quad \text{ר' } \wedge \quad \bar{x}_i \wedge \bar{x}_j = 0 \end{aligned}$$

ההנחתה דהיה בידנו $C \subseteq X$ המהווה חצפה הנילו (II)
 $C = (x_1, \dots, x_d, \bar{x}_d)$: $x_i \in \{0, 1\}$

$$h_i(x) = \begin{cases} 1 & \text{if } i \neq j \\ 0 & \text{else} \end{cases} \quad \text{ר' } h_i, \quad \text{ההנחתה}$$

$$\begin{aligned} h_1(x_1, \dots, x_d, \bar{x}_d) &= (0, 1, 1, \dots, 1) \\ h_2(x_1, \dots, x_d, \bar{x}_d) &= (1, 0, 1, \dots, 1) \end{aligned} \quad \text{ר' } h_1, h_2$$

$$h_{d+1}(x_1, \dots, x_d, \bar{x}_d) = (1, 1, 1, \dots, 1, 0)$$

ההנחתה דהיה $(x, y) \in (X \times Y)$ מתקיימת אם ורק אם $x \in C$ ו- $y = h_i(x)$ עבור כל $i \in [d+1]$.

ההנחתה דהיה $x \in C$ מתקיימת אם ורק אם $x \in \{0, 1\}^d$ ו- $x \in \{0, 1\}^{d+1}$.

$\therefore l_1 = l_2$ PAC (1)

$$h_1(x_1) = 0 \wedge h_1(x_2) = 1 \quad \text{ר'ג'נ'ר'ה} \quad h_1(\cdot) \text{ מוגדרת כפונקציית}$$

$$h_2(x_1) = 0 \wedge h_2(x_2) = 1 \quad \text{ר'ג'נ'ר'ה} \quad l_1 = l_2 \quad \text{ו-}$$

$\therefore h_2(\cdot) \text{ מוגדרת כפונקציית}$

$$h_2(x_1) = 1 \wedge h_2(x_2) = 0$$

$\therefore l_1 \neq l_2$ PAC (2)

$$h_1(x_3) = 1 \quad \text{ר'ג'נ'ר'ה} \quad h_1(\cdot) \text{ מוגדרת כפונקציית}$$

$$h_2(x_3) \neq 1 \quad \text{ר'ג'נ'ר'ה} \quad l_1 \neq l_2 \quad \text{ו-}$$

$\Rightarrow h_2(x_3) = 0$

$$h_2(x_k) = 0 \iff k=2$$

$k=3$ ר'ג'נ'ר'ה PAC

$$\Rightarrow h_i(x_i) = 0 \wedge h_i(x_j) = 1 \quad \text{ולפ'ג'ן מוגדרות ה-VC-dim}$$

$$h_j(x_i) = 0 \wedge h_j(x_j) = 1 \quad i \neq j \quad \text{ר'ג'נ'ר'ה}$$

$l_i = l_j$ ר'ג'נ'ר'ה מוגדרות ה-VC-dim של פונקציית ה- h_i

$$h_j(x_i) = 0 \iff i=j \quad \text{ר'ג'נ'ר'ה}$$

$$h^*(x_k) = 1 \quad k \neq i, i \neq j \quad \text{ר'ג'נ'ר'ה} \quad l_i \neq l_j \quad \text{ר'ג'נ'ר'ה}$$

$$\Rightarrow h_j(x_k) \neq 1$$

$$\Rightarrow h_j(x_k) = 0$$

$h_j(x_k) = 0 \iff j=k \quad \text{ר'ג'נ'ר'ה}$

$H_{\text{con}} \rightarrow d+1$ בואו נסמן C כ-VC-dim של H_{con} ו- $d+1$ כ-VC-dim של $H_{\text{con}} \setminus \{x_k\}$

$$\text{VCdim}(H_{\text{con}}) \leq d+1$$

4) תבונת על-uniform convergence $\Pr_{\mathcal{H}}[\text{error}] \leq \delta$: $H = \mathcal{H}$

sample complexity \geq Agnostic PAC bound for H : \mathbb{B}
 $m_H(\epsilon, \delta) \leq m_H(\epsilon/2, \delta)$

$\mathcal{E}, \mathcal{S} \subset \{0,1\}$ גור P $m_H^{\text{uc}}(\{0,1\})^2 \rightarrow N$ גודל הדוגמה N גודל הדוגמה
 $\mathcal{H} \subset \mathcal{S}$ PAC $\mathcal{X} \times \mathcal{Y}$ גודל הדוגמה N גודל הדוגמה
 \mathcal{H}, D iid דוגמאות מ- \mathcal{S} $m \geq m_H^{\text{uc}}(\epsilon, \delta)$ גודל הדוגמה
 $\frac{\epsilon}{2}$ -representative \mathcal{S} , $1-\delta$ נסוכן הטעות

$\Pr[S|S \text{ is } \frac{\epsilon}{2}\text{-representative}] \geq 1-\delta$ כוונת סט הסAMPLE
 \mathcal{S} representative \mathcal{S} training set PWC

$$\forall h \in \mathcal{H} \quad |L_S(h) - L_D(h)| \leq \frac{\epsilon}{2} \iff -\frac{\epsilon}{2} \leq L_S(h) - L_D(h) \leq \frac{\epsilon}{2}$$

$$L_D(h_s) \leq \min_{h \in \mathcal{H}} L_D(h) + \frac{\epsilon}{2} \text{ PWC} \quad h_s \in \arg \min_{h \in \mathcal{H}} L_D(h) + \frac{\epsilon}{2} \text{ PWC}$$

$$L_D(h_s) \leq L_S(h_s) + \frac{\epsilon}{2} \text{ representative } \mathcal{S} \text{ of } \mathcal{D} \quad L_S(h_s) \leq L_S(h) + \frac{\epsilon}{2}$$

$$L_S(h_s) \leq L_S(h) + \frac{\epsilon}{2} \text{ PAC proved } h_s \text{ PWC}$$

$$L_D(h_s) \leq L_S(h) + \frac{\epsilon}{2} \leq L_S(h) + \frac{\epsilon}{2} \leq L_D(h) + \frac{\epsilon}{2} + \frac{\epsilon}{2}$$

$$L_D(h) \leq L_S(h) + \frac{\epsilon}{2} \text{ PAC } \frac{\epsilon}{2} \text{ representative } \mathcal{S}$$

$$= L_D(h) + \frac{\epsilon}{2} \Rightarrow \boxed{L_D(h_s) \leq \min_{h \in \mathcal{H}} L_D(h) + \frac{\epsilon}{2}}$$

$$\Pr_{\text{SNDM}}[L_D(h_s) \leq \min_{h \in \mathcal{H}} L_D(h) + \frac{\epsilon}{2}] \geq 1-\delta$$

$$\Pr_{\text{SNDM}}[S|S \text{ is } \frac{\epsilon}{2}\text{-representative}] \geq 1-\delta$$

$X \times Y$ גודל הדוגמה ב- $\mathcal{E}, \mathcal{S} \subset \{0,1\}$ גודל הדוגמה N

$$m \geq m_H^{\text{uc}}\left(\frac{\epsilon}{2}, \delta\right)$$

$$\Pr_{\text{SNDM}}[L_D(h_s) \leq \min_{h \in \mathcal{H}} L_D(h) + \frac{\epsilon}{2}] \geq 1-\delta$$

Agnostic PAC bound for H - ϵ PWC

Monotonicity

?) $\text{VCdim}(H_1) \leq \text{VCdim}(H_2)$ $H_1 \subseteq H_2$
 $\text{VCdim}(H_2) \geq \text{VCdim}(H_1)$:

אנו מוכיחים ש $|H_1| = 2^m$ \Leftrightarrow $C \subseteq X$ מושתת H_1 מושתת \Leftrightarrow C מושתת H_2

$\text{VCdim}(H_1) = \sup \{ m \in \mathbb{N} : \exists C \text{ such that } |C|=m \text{ and } H_1 \text{ shatters } C \}$

$\text{VCdim}(H_1) = m \iff C = \{C_1, \dots, C_m\}$

$|H_1| = 2^m \iff C \text{ מושתת } H_1$

$h_i \in H_1 \Rightarrow h_i \in H_2$ $\forall i$ $H_1 \subseteq H_2$

- א. C מושתת H_1 \Leftrightarrow C מושתת H_2 \Leftrightarrow C מושתת H_1

$H_{1C} = \{h_{1C} = h_1(C_1), \dots, h_1(C_m) \mid h_1 \in H_1\}$

$H_{2C} = \{h_{2C} = h_2(C_1), \dots, h_2(C_m) \mid h_2 \in H_2\}$

$2^m = |H_{1C}| \leq |H_{2C}| \leq 2^m \iff |H_{1C}| = |H_{2C}| \iff |H_1| = |H_2| \iff H_1 \subseteq H_2$

הוכחה בדרכו של הוכחה של הוכחה, כלומר, C מושתת H_1 \Leftrightarrow C מושתת H_2

נניח C מושתת H_2 \Leftrightarrow C מושתת H_1 \Leftrightarrow C מושתת H_2

$C \text{ מושתת } H_2 \Leftrightarrow C \text{ מושתת } H_1$

$\text{VCdim}(H_1) \leq \text{VCdim}(H_2)$

נניח $H_1 \subseteq H_2$ $C \subseteq X$ מושתת H_2 \Leftrightarrow C מושתת H_1 - $\text{VCdim}(H_1) \leq \text{VCdim}(H_2)$

$H_2 \subseteq C \subseteq X$ מושתת H_2 \Leftrightarrow C מושתת H_2 - $\text{VCdim}(H_2) \leq \text{VCdim}(H_1)$

בנוסף m מושתת H_2 מושתת H_1 \Leftrightarrow $m \leq \text{VCdim}(H_2)$

$$\text{לע' } \chi \text{ נס饱ת הטענה } H \subseteq \chi \text{ כ' כי } H \subseteq C \text{ ו } C \subseteq \chi \text{ ג' } \quad (8)$$

$T_H(H) : N \rightarrow N$

$$T_H(H) = \max \{ |H(c)| ; c \subseteq \chi, |c|=m \}$$

ההו סבבון מינימלי (הטענה) (a)
שיהי כפונקציית שיבוב ϕ כפונקציית שיבוב
(כ' סטטיסטיקת סטטיסטיקת גנרטור)
עכ' בדוגמה שown כפונקציית שיבוב (ב' אוניברסיטאי)

גיאו רצוי ש ϕ יש שיבוב הטענה H כפונקציית שיבוב (כ' סטטיסטיקת גנרטור)
כפונקציית שיבוב (ב' אוניברסיטאי) ϕ כפונקציית שיבוב (ב' אוניברסיטאי)

$T_H(m) \leq 2^m$ (ב' אוניברסיטאי)
 $T_H(m) \geq 2^m$ (ב' אוניברסיטאי) $\Rightarrow T_H(m) = 2^m$ (ב' אוניברסיטאי)
ר' ע' $VC\dim H = \infty$ (ב' אוניברסיטאי) $\Rightarrow m < VC\dim H$ (ב' אוניברסיטאי) (b)

ר' ע' $T_H(m) \leq 2^m$ (ב' אוניברסיטאי) $\Rightarrow m \leq VC\dim H$ (ב' אוניברסיטאי)

$$H(c) \subseteq \{\pm 1\}^m \Rightarrow |H(c)| \leq 2^m$$

ב' אוניברסיטאי 2^m מיל' ג' Q

$$T_H(m) = 2^m \text{ מיל' ג' } \Leftrightarrow VC\dim(H) = \infty$$

ר' ע' $VC\dim H \leq m$ (ב' אוניברסיטאי) $\Rightarrow T_H(m) \leq 2^m$ (ב' אוניברסיטאי)
ר' ע' $VC\dim H \geq m$ (ב' אוניברסיטאי) $\Rightarrow T_H(m) \geq 2^m$ (ב' אוניברסיטאי)

ר' ע' $VC\dim H \leq m$ (ב' אוניברסיטאי) $\Rightarrow T_H(m) \leq 2^m$ (ב' אוניברסיטאי)
ר' ע' $VC\dim H \geq m$ (ב' אוניברסיטאי) $\Rightarrow T_H(m) \geq 2^m$ (ב' אוניברסיטאי)
 $VC\dim(H) = \max_m \{ m | T_H(m) = 2^m \}$ (ב' אוניברסיטאי)

ר' ע' $VC\dim(H) \leq d$ (ב' אוניברסיטאי) $\Rightarrow T_H(m) = 2^m$ (ב' אוניברסיטאי)
 $T_H(m) \leq 2^m$ (ב' אוניברסיטאי) $\Rightarrow m \leq d$ (ב' אוניברסיטאי) (c)

$$d = \max_m \{ m | T_H(m) = 2^m \}$$

$$|H(c)| \leq 2^m \text{ מיל' ג' } \Rightarrow m \leq d \text{ מיל' ג' } \Leftrightarrow$$

$$T_{\leq d}(m) = \max \{ |H(c)| ; c \subseteq \chi, |c|=m \} = 2^m$$

$$T_H(m) = 2^m \text{ מיל' ג' } \Rightarrow m \leq d \text{ מיל' ג' } \Rightarrow VC\dim(H) = d \text{ מיל' ג' } \Rightarrow$$

$$T_{\leq d}(m) = 2^m \text{ מיל' ג' } \Rightarrow m \leq d \text{ מיל' ג' } \Rightarrow VC\dim(H) = d \text{ מיל' ג' }$$

$$m \geq d \quad \text{dim } H = d \quad \text{dim } V = d$$

$H_C \leq |\{B \subseteq C \mid H \text{ shatters } B\}|$ (i)
 $\text{dim } H = d \iff |\{B \subseteq C \mid H \text{ shatters } B\}| = 2^d$ (ii)

$$C = \{C_i\} \quad m = 2^d$$

$H_C = \{h_C = h(C_1), \dots, h(C_m) : h_C(\{C_i\}) \subseteq H \text{ for all } i\}$
 $|H_C| \leq 2^d \iff H_C \subseteq \{0, 1\}^{2^d}$

$H_C \subseteq C \iff H_C \text{ כרירה מושלמת}$

$B = C \iff B = \emptyset \iff B \subseteq C \iff H \text{ מושם}$
 $B \subseteq C \iff H \subseteq H_C \iff H \subseteq H_C \iff H \subseteq H$.

$$|\{B \subseteq C \mid H \text{ shatters } B\}| = 2^d \iff$$

$B = \emptyset \iff H \text{ מושם}$

$$|H_C| = 2^d = |\{B \subseteq C \mid H \text{ shatters } B\}|$$

$B = C \iff H \text{ מושם} \iff H \subseteq H_C \iff H \subseteq H$.

$$H \text{ מושם} \iff H \subseteq H_C \iff |\{B \subseteq C \mid H \text{ shatters } B\}| = 1 \iff$$

$$|H_C| = 1 \iff H \subseteq H_C \iff H \subseteq H$$

$$|H_C| = 1 = |\{B \subseteq C \mid H \text{ shatters } B\}|$$

הוכחה

$C' = \{C_1, \dots, C_m\}, C = \{C_1, \dots, C_m\} \subseteq H$

$$|H_{C'}| = 1 \iff \{(y_2, -y_m) : (0, y_2, -y_m) \in H_C \wedge (1, y_2, -y_m) \in H_C\} = \emptyset$$

$$\Psi = \{(y_2, -y_m) : (0, y_2, -y_m) \in H_C \wedge (1, y_2, -y_m) \in H_C\} = \emptyset$$

$$|H_C| = |H_{C'}| + |\Psi|$$

$$|H_C| \leq |\{B \subseteq C \mid H \text{ shatters } B\}| = |\{B \subseteq C : C \not\subseteq B \wedge H \text{ shatters } B\}|$$

$$H' = \{h'_C : \exists h' \in H \text{ st } (1-h'_C, h'_C(2), h'_C(m)) : h'_C \subseteq H'\} \subseteq H$$

$$= \{h(C_1), h(C_2), \dots, h(C_m)\}$$

$$h(C_1) = h(C_1) \cap (C_1 \cup \{m\}) \subseteq H'$$

$$|\Psi| = |H_{C'}| = |\{B \subseteq C' : H' \text{ shatters } B\}| = |\{B \subseteq C' : C \not\subseteq B \wedge H' \text{ shatters } B\}|$$

$$|\{B \subseteq C' : H' \text{ shatters } B \cup \{m\}\}| = |\{B \subseteq C' : C \not\subseteq B \wedge H' \text{ shatters } B\}| \leq$$

$$|\{B \subseteq C' : C \not\subseteq B \wedge H' \text{ shatters } B\}|$$

(i) d part

$$|H(c)| \leq |\{B \subseteq C' \mid c_1 \notin B \wedge H \text{ shatters } B\}|$$

$\cap H(c)$

$$|H(c')| \leq |\{B \subseteq C' \mid c_1 \in B \wedge H \text{ shatters } B\}|$$

$$|H(c)| = |H(c')| + |H(c')| \leq |\{B \subseteq C' \mid c_1 \notin B \wedge H \text{ shatters } B\}| - \emptyset \cup H(c)$$

$$+ |\{B \subseteq C' \mid c_1 \in B \wedge H \text{ shatters } B\}| = |\{B \subseteq C' \cup \{c_1\} \mid H \text{ shatters } B\}|$$

$$|H \text{ shatters } B| = |\{B \subseteq C \mid H \text{ shatters } B\}|$$

$$C = \{C_1, \dots, C_m\} = \{C_1, \dots, C'_1\} \cup \{C'_1, \dots, C_m\}$$

$$(\{C_1\} \cap C'_1) \cap (\{C'_1\} \cap C_1) = \emptyset$$

$$|\{B \subseteq C : H \text{ shatters } B\}| \leq \sum_{k=0}^d \binom{m}{k} \quad \text{ו"הו ש } C \subseteq X \text{ ב } H, \text{ ו"הו } + \text{ (iii)} \quad (d)$$

$$C = \{c_1, \dots, c_m\}$$

$\exists C \subseteq X$ ש C מתקשר ב H (לפחות d קבוצות) ו H משבירה C (לפחות d קבוצות) ב H

$$|\{B \subseteq C : H \text{ shatters } B\}| \leq |C| \leq \binom{d}{d}$$

הטענה היא ש H משבירה C ב H (לפחות d קבוצות) \Leftrightarrow $\forall m \in \binom{d}{d}$ $\exists C \subseteq X$ ש $|C|=m$ ו H משבירה C ב H

$$|C| = \sum_{k=0}^m \binom{m}{k}$$

$$|\{B \subseteq C : H \text{ shatters } B\}| \leq |C| = \sum_{k=0}^d \binom{m}{k}$$

$\sup \{m \in \mathbb{N} : \exists C \text{ such that } |C|=m \text{ and } \forall H \text{ shatters } C \} = \text{VC dim}(H) = d$

תנאי תבונת H -ה ש- C ל H , מ"מ H משבירה C ב H

$$\sum_{k=0}^d \binom{m}{k} \leq \left(\frac{em}{d}\right)^d \quad \Rightarrow \text{ (ii) (iv)}$$

$$T_H(m) = \max \{ |Hc| : C \subseteq X, |C|=m \}$$

$$\leq \max \{ |\{B \subseteq C : H \text{ shatters } B\}| : C \subseteq X, |C|=m \}$$

$$\leq \max \{ \sum_{k=0}^d \binom{m}{k} \}$$

$$\leq \left(\frac{em}{d}\right)^d$$

$$T_H(m) = 2^m = 2^d \quad \Rightarrow \text{ (iii), (iv)} \quad m=d \quad \text{nic} \quad (e)$$

$$T_H(m) \leq \left(\frac{em}{d}\right)^d = e^d \quad \text{לפי (ii) (iv) (v)}$$

$$(2^d \leq e^d)$$

$$|\{B \subseteq C : H \text{ shatters } B\}| \leq \sum_{k=0}^d \binom{m}{k} = \sum_{k=0}^m \binom{m}{k} \quad \Rightarrow \text{ (iii) } d=m$$

$m=d$ נוכן

$$\text{VC dim} = \max \{ d \mid \exists C \subseteq X \text{ st } |C|=d \text{ and } T_H(C) = 2^d \} \quad (f)$$

$$m \leq \text{VC dim}(H) \quad \text{נוב}$$

$$\text{VC dim} = \max \{ d \mid \exists C \subseteq X \text{ st } |C|=d \text{ and } T_H(C) \leq \left(\frac{em}{d}\right)^d \}$$

$$m > \text{VC dim}(H) \quad \text{נוב}$$

IML EX4


10.

10. In ex4_tools you are provided with the function generate_data. Use it to generate 5000 samples without noise (i.e. noise_ratio=0). Train an Adaboost classifier over this data. Use the DecisionStump weak learner mentioned above, and $T = 500$. Generate another 200 samples without noise ("test set") and plot the training error and test error, as a function of T . Plot the two curves on the same figure.




בנוסף צרפתו גרפים שמציגים את השגיאה של האימון והשגיאה של הטוט על T בסדר הבא :

T = 5
T=10
T=50
T=100
T=200
T=500



11.

11. Plot the decisions of the learned classifiers with $T \in \{5, 10, 50, 100, 200, 500\}$ together with the test data. You can use the function `decision_boundaries` together with `plt.subplot` for this purpose.




12.

12. Out of the different values you used for T , find \hat{T} , the one that minimizes the test error. What is \hat{T} and what is its test error? Plot the decision boundaries of this classifier together with the training data.

minimal test error is : 0.005 with T : 105


num classifiers = 105



13.

13. Look into the AdaBoost: Take the weights of the samples in the last iteration of the training (D^T). Plot the training set with size proportional to its weight in D^T , and color that indicates its label (again, you can use `decision_boundaries`). Oh! we cannot see any point! the weights are too small... so we will normalize them: $D = D / \text{np.max}(D) * 10$. What do we see now? can you explain it?

num classifiers = 500



השימוש במשקלים המתקבלים באיטרציה الأخيرة במהלך האימון בא ידי ביטוי בהציגת הדadata ביחס לגודלו הנקודות.

מואופן תיאור האלגוריתם של adaboost אנו נתונים יותר משקל לדוגמאות שטעינו עליהם לעומת דוגמאות שצדקנו עליהם. כך שנצפה שבאייטרציה האחרונה חלוקת המשקלים תהיה בהתאם, כאשר עיקר הטעויות יהיו באזוריים בהם יש קרבה בין נקודות עם תיוגים שונים. במילים אחרות יהיה קשה יותר לסווג את הנקודות הקרובות לגבול במובן שהאלגוריתם יטעה עליהם פעמים רבות.


כפי שניתן לראות הנקודות הבולטות ביותר נמצאות על הגבול שמספריד בין דוגמאות עם תיוגים שונים. וזה מתיישב עם אופן פעולה האלגוריתם של adaboost שיטה פעמים רבות בסיווג של נקודות אלו (כלומר יתנו להן תיוג שגוי) וכן בכל אייטרציה המשקל שלהם יגדל. לעומת זאת עברו הנקודות הרחוקות מאוד מהגבול ונמצאות בקצוות יהיו קלות לסיווג כלומר האלגוריתם לאחר מספר קטן של אייטרציות יסוויג אותן עם התיוג הנכון. מכאן שהן יהיו בעלות משקלים קטנים יותר משמעותית.

14.

14. Repeat [10](#)[11](#)[12](#)[13](#) with noised data. Try `noise_ratio=0.01` and `noise_ratio=0.4`.


- Add all the graphs to the pdf.
- Describe the changes.
- Explain [10](#) in terms of the bias complexity tradeoff.
- Explain the differences in [12](#).

noise ratio = 0.01




minimal test error is : 0.015 with T : 72

num classifiers = 72





num classifiers = 500





noise ratio = 0.4

Training set error and test set error as a function of T



minimal test error is : 0.34 with T : 59



ניתוח הגרפים :

noise ratio = 0.4	noise ratio = 0.01	noise ratio = 0	
0.34	0.015	0.005	minimal test error
59	72	105	T that minimize the error

נבחן כי עם המدد של שגיאה מינימלית על קבוצת הטסט ככל שהערך של noise ratio יותר גדול כך השגיאה המינימלית גדלה.

המשמעות של noise ratio היא יחס הדגימות עבורי הנפוך את התוצאות בסט של האימון. כמו כן רואים כי עבור דאטא ללא רעש השגיאה המינימלית מתקבלת עבור T הגadol ביותר ביחס לדאטא מושרע. כאשר יש הבדל בין דאטא מאד מושרע עם noise ratio של 0.4 ובו השגיאה המינימלית מתקבלת עם 59 מושגים ולעומת זאת עבור דאטא מעט מושרע עם noise ratio של 0.01 השגיאה המינימלית מתקבלת עם 72 מושגים.

בסך הכל ככל שהדאטא יותר מושרע נקבל שגיאה מינימלית עם פחות מושגים שכן הרבה מושגים יגרמו לOverfitting, וכן השגיאה המינימלית גדלה ככל שיש יותר רעש.

השינויים בגרפים :

- גרפּ השגיאה של test set ושל ה training set

אנו רואים שינוי משמעותי מהתויג לא נכון - קלומר רעש חזק. השגיאה מתחילה ב ~ 0.41 ועבור סט האימון יורדת עד ~ 0.33 ועבור הטסט סט יורדת ל 0.34 אך עולה בהוספה עוד מושגים ל ~ 0.37.

זאת לעומת המקרה בו אין רעש כלל או רעש נמוך יחסית של 0.01 בהם השגיאה מתחילה ב ~ 0.2 ו יורדת ל 0.015 עבור דאטא עם רעש 0.01 ועוד 0.005 עבור דאטא לא מושרע ביחס לטסט סט. מבחינת סט האימון השגיאה קטנה יותר במקרה של דאטא לא מושרע.

• גרפּ של החלטות שקיבלו המושגים המאומן על ה test data על כל T שמייצג את מספר המושגים בהקשר של טסט סט עבור דאטא לא רועש ככל שמספר מושגים גדול קר השגיאה קטנה. בשלב השלישי ניתן לראות שאין שינוי משמעותי ביחס למספר המושגים T. עבור דאטא רועש מאוד (0.4) יותר מ - 100 מושגים נתנו תוצאות טובות ככלומר שגיאה גדולה יותר לעומת פחות מ 100 מושגים.

• גרפּ של ה decision boundaries של המושג שעבורו קיבלנו את השגיאה המינימלית על סט האימון כאשר הדאטא רועש מאוד 0.4 - הנקודות מבולגות וקשה לראות הפרדה לעומת המקרה שבו רואים הפרדה מוחלטת בין נקודות כחולות ואדומות עם דאטא לא רועש. כאשר הדאטא רועש במידה מוגעתה 0.01 - יש טיעיות לומר ניתן לראות נקודות אדומות בשטח של הכחולות ולהיפר אבל מעט יחסית.

• גרפּ של ה decision boundaries עם המשקלים של האיטרציה الأخيرة מבוחנת הנקודות הבולטות שיש להן משקלים גדולים ניתן לראות במקירה של דאטא מושרע במידה מוגעתה 0.01 - יש נקודות כחולות בולטות שרחוקות מאייזור הגבול המפריד, בנגדוד למקרה שהואינו רצויים. שכן בדאטא לא מושרע ראים כי הנקודות מסביב לגבול הן אלה שקיבלו משקלים חזקים ונקודות רחוקות יותר קיבלו משקלים נמוכים מאוד.

כאשר הדאטה רועש מאוד מ-0.4 - הרבה נקודות קיבלו משקלים גדולים, בנוסף לא ניתן לראות כלל הימצאות של נקודות עם משקלים גבוהים ספציפית על הגבול המפרד בין נקודות עם תיוגים שונים.

Bias-complexity tradeoff

ונכל לפרק את שגיאת ה-ERM לסכום של שגיאת הקירוב ושגיאת השערור. Bias-complexity tradeoff משומש לנו ממעוניינים למצער את השגיאה הכלולת אנחנו מתמודדים עם ה- overfitting. מצד אחד בחירת מחלוקת היפותזות שהיא עשויה תפחית את שגיאת הקירוב, אך עלולה להגדיל את שגיאת השערור שכן עלול להיות underfitting. מצד שני אם נבחר מחלוקת היפותזות שהיא קטנה קצתן את שגיאת השערור אך יתכן כי נגדיל את שגיאת הקירוב שכן זה עלול להוביל ל-

ה learner מתמודד עם בעיה של בחירת tradeoff טוב בין שני השיקולים, boosting מסיע לו בבחירה מחלוקת היפותזות כך ששגיאת הקירוב ושגיאת השערור לא יהיו גדולות. AdaBoost מאפשר לנו לשנות ב tradeoff בין שגיאות הקירוב והשערור על ידי שינוי פרמטר יחיד - T מספר המסויים.

השימוש בboosting מאפשר learner להתחיל עם מחלוקת בסיסית שעבורה יתכן כי שגיאת הקירוב תהיה גדולה, וככל שננו מתקדמים באיטרציות ומספר המסויים גדל, מחלוקת ההיפותזות תהיהعشירה יותר. כפי שאנו רואים בגרפים ניתן לראות שהחל מ- $T=500$ שיפור ממשמעותי.

מהגרף נסיק כי עבור דאטה ללא רעש הגדלה של מספר המסויים T תגרום להפחיתה בbias ותשמר variance נמוך. מכאן ששגיאת השערור תהיה קטנה יותר ככל ש-T גדול יותר. יתכן שעבור T גדול מאד ($T=500$) השיפור מבחינת bias יהיה מינורי (הפחתה לא משמעותית) בהשוואה ל variance. בהתאם החלט $T=200$ ועד $T=500$ אנו רואים בgraf של השגיאה כי יש התיצבות ואין שינוי משמעותי בירידה של השגיאה.

במקרה של דאטה עם רעש **0.01** עבור T קטן יותר תתקבל שגיאת קטנה יותר לעומת דאטה ללא רעש בו T גדול יותר יתכן שగיאת קטנה יותר. במקרה של דאטה עם רעש 0.01 השגיאה המינימלית תתקבל עם 72 מסויים לעומת 105 בדאטה ללא רעש. במקרה של דאטה מושפע מ-**0.4** אנו רואים שיפור מבחינת סט האימון עד $T \sim 150$ והטוטט סט עד $T \sim 59$, מבחינת הטוטט סט יש עלייה בשגיאת החל מ- $T > 59$. כאשר הדאטה רועש שימוש ב-**C** גדול יגרום ל- overfitting ושגיאת הערכה תגדל כך שהשגיאה המיויחסת לטוטט סט תהיה גדולה וננו רואים אף עלייה בשגיאת.

שגיאת הקירוב - The Approximation Error

This term measures how much risk we have because we restrict ourselves to a specific class, namely, how much inductive bias we have. The approximation error does not depend on the sample size and is determined by the hypothesis class chosen. Enlarging the hypothesis class can decrease the approximation error.

שגיאת השערור - The Estimation Error

The difference between the approximation error and the error achieved by the ERM predictor. The estimation error results because the empirical risk (i.e., training error) is only an estimate of the true risk, and so the predictor minimizing the empirical risk is only an estimate of the predictor minimizing the true risk.